

Erreurs numériques : Une introduction élémentaire

C. Troestler

4 mars 2025

Problèmes


Un exemple standard : Let $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ be the function

$$f(x, y) = (333.75 - x^2)y^6 + x^2(11x^2y^2 - 121y^4 - 2) + 5.5y^8$$

On veut évaluer $f(77617, 33096)$.

⇒ `src/bin/num_error.rs`

Un exemple plus simple $f(x) = \frac{1 - (1 - x)}{x}$.



Problèmes



Un exemple standard : Let $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ be the function

$$f(x, y) = (333.75 - x^2)y^6 + x^2(11x^2y^2 - 121y^4 - 2) + 5.5y^8$$

On veut évaluer $f(77617, 33096)$.

⇒ `src/bin/num_error.rs`

Un exemple plus simple $f(x) = \frac{1 - (1 - x)}{x}$.



Problèmes



Un exemple standard : Let $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ be the function

$$f(x, y) = (333.75 - x^2)y^6 + x^2(11x^2y^2 - 121y^4 - 2) + 5.5y^8$$

On veut évaluer $f(77617, 33096)$.

⇒ `src/bin/num_error.rs`

Un exemple plus simple $f(x) = \frac{1 - (1 - x)}{x}$.



IEEE Standard 754 (1985)

Représentation normalisée :

$$x = \pm \underbrace{[1.m_1 \dots m_{p-1}]_2}_{\text{mantisse}} \cdot 2^e$$

Précision	p	$e_{\min}$	$e_{\max}$	# bits e	biais
simple f32	24	-126	127	8	127
double f64	53	-1022	1023	11	1023

⇒ `src/bin/num_repr.rs`

Unit in the last place (ulp) :

$$\text{ulp}(x) := 2^{-(p-1)} \cdot 2^e$$

Autres valeurs :

- ± 0 (tous les bits de e et m sont 0),
- $\pm \infty$ et NaN (tous les bits de e sont 1);
- dénormalisés (tous les bits de e mais pas de m sont 0).

IEEE Standard 754 (1985)

Représentation normalisée :

$$x = \pm \underbrace{[1.m_1 \dots m_{p-1}]_2}_{\text{mantisse}} \cdot 2^e$$

Précision	p	$e_{\min}$	$e_{\max}$	# bits e	biais
simple f32	24	-126	127	8	127
double f64	53	-1022	1023	11	1023

⇒ `src/bin/num_repr.rs`
Unit in the last place (ulp) :

$$\text{ulp}(x) := 2^{-(p-1)} \cdot 2^e$$

Autres valeurs :

- ± 0 (tous les bits de e et m sont 0),
- $\pm \infty$ et NaN (tous les bits de e sont 1);
- dénormalisés (tous les bits de e mais pas de m sont 0).

IEEE Standard 754 (1985)

Représentation normalisée :

$$x = \pm \underbrace{[1.m_1 \dots m_{p-1}]_2}_{\text{mantisse}} \cdot 2^e$$

Précision	p	$e_{\min}$	$e_{\max}$	# bits e	biais
simple $\mathbb{F}_{32}$	24	-126	127	8	127
double $\mathbb{F}_{64}$	53	-1022	1023	11	1023

`src/bin/num_repr.rs`

Unit in the last place (ulp) :

$$\text{ulp}(x) := 2^{-(p-1)} \cdot 2^e$$

Autres valeurs :

- ± 0 (tous les bits de e et m sont 0),
- $\pm \infty$ et NaN (tous les bits de e sont 1);
- dénormalisés (tous les bits de e mais pas de m sont 0).

Références

- David MONNIAUX, [The pitfalls of verifying floating-point computations](#), ACM Transactions on Programming Languages and Systems (TOPLAS), Volume 30, Issue 3, Article No. 12, p. 1–41. [arXiv](#)
- David Goldberg, [What every computer scientist should know about floating-point](#), ACM Computing Surveys (CSUR), Volume 23, Issue 1, p. 5–48, 1991.
- William KAHAN, [How Java's Floating-Point Hurts Everyone Everywhere](#).