

Notes de Cours de Probabilités

M. Vitto

Bac 2 Mathématiques

19 mai 2025

Table des matières

1	Axiomatique et Calcul des probabilités	3
1.1	Un premier regard sur les probabilités	3
1.2	Interprétation fréquentiste et équiprobabilité	4
1.3	Analyse Combinatoire	4
1.3.1	Principe du dénombrement (ou principe multiplicatif)	4
1.3.2	Permutations	5
1.3.3	Arrangements et Combinaisons (Nombre de sous-ensembles)	5
1.3.4	Modèles classiques d'urnes	6
1.3.5	Triangle de Pascal et Identité de Pascal	7
1.3.6	Binôme de Newton	8
1.3.7	Combinatoire et Récursions	9
1.4	Exemple : Paradoxe des anniversaires	10
1.5	Axiomatique des Probabilités (Kolmogorov)	10
1.6	Probabilités Conditionnelles et Indépendance	14
1.7	Suites d'Événements	18
2	Variables Aléatoires	21
2.1	Variables aléatoires et leur loi	21
2.2	Variable Aléatoire Discrète	23
2.3	Variables Aléatoires Continues	25
2.3.1	Interprétation de la densité	26
2.3.2	Quelques Variables Aléatoires Continues Usuelles	27
2.4	Remarque : Variable aléatoire générale	30
2.5	Propriétés de l'espérance (cas général)	31
3	Distributions Jointes, Indépendance	32
3.1	Fonction de répartition jointe	32
3.2	Cas où (X, Y) est un couple de variables aléatoires discrètes	32
3.3	Cas où (X, Y) est un couple de variables aléatoires (absolument) continues	34
3.4	Lois Marginales	34
3.5	Indépendance de Variables Aléatoires	35

3.6	Covariance entre deux Variables Aléatoires	36
4	Vecteurs Aléatoires	38
4.1	Fonction de répartition d'un vecteur aléatoire	38
4.2	Indépendance mutuelle des composantes	38
4.3	Espérance d'un vecteur aléatoire	39
4.4	Matrice de Covariance	39
4.5	Distribution Multinomiale	39
4.6	Distributions Conditionnelles	41
4.7	Espérance Conditionnelle comme Variable Aléatoire	42
5	Inégalités, Convergences et Théorème Limite	45
5.1	Inégalités de Probabilités	45
5.1.1	Inégalité de Markov	45
5.1.2	Inégalité de Bienaymé-Tchebychev	46
5.1.3	Inégalité de Jensen	46
5.2	Convergences de Suites de Variables Aléatoires	48
5.2.1	Convergence en Distribution (ou en Loi)	48
5.2.2	Convergence en Probabilité	49
5.2.3	Convergence Presque Sûre	49
5.2.4	Convergence en Moyenne (d'ordre r ou en L^r)	50
5.3	Comparaisons des modes de convergence	50
5.4	Fonction Caractéristique	51
5.5	Théorèmes Limites	52
5.5.1	Théorème Central Limite (TCL) - Version de Lindeberg-Lévy	52
5.5.2	Loi Faible des Grands Nombres (LFGN)	53
5.5.3	Loi Forte des Grands Nombres (LFFGN)	54

1 Axiomatique et Calcul des probabilités

1.1 Un premier regard sur les probabilités

On s'intéresse à une **expérience aléatoire**, c'est-à-dire (i.e., une expérience dont les résultats possibles sont connus, mais dont le résultat est inconnu et dépend du hasard.

Définition 1.1 (Univers). L'univers, noté Ω , est l'ensemble des résultats possibles.

Exemple 1.2. — Lancer d'un dé : $\Omega = \{1, 2, 3, 4, 5, 6\}$.

— Lancer de deux pièces (P pour Pile, F pour Face) : $\Omega = \{(P, P), (P, F), (F, P), (F, F)\}$.

— Durée de vie d'une machine : $\Omega = [0, +\infty[$ (intervalle, ensemble non fini).

Définition 1.3 (Événement). Un **événement** est un sous-ensemble de Ω .

Exemple 1.4. — Lancer de dé :

— $A = \{1, 2, 3\} = \{\text{le résultat est } \leq 3\}$ (Notation de la note originale : « $E_{\leq 3}$ » événement).

— $B = \{2, 4, 6\} = \{\text{le résultat est pair}\}$.

— Durée de vie machine : $C = \{0\} \cup [3, +\infty[= \{\text{durée de vie nulle ou } \geq 3 \text{ (ans, unités, etc.)}\}$.

Un événement A est **réalisé** si $\omega \in A$, où ω est l'élément de Ω choisi comme résultat.

Définition 1.5 (Événements triviaux). — Ω est l'**événement certain**.

— $\emptyset$ (ou noté aussi $\{\}$) est l'**événement impossible**.

(Leur chance de se produire est connue : soit 100% soit 0%.)

Si A et B sont des événements :

— $A \cup B = \{A \text{ se réalise ou } B \text{ se réalise}\}$

— $A \cap B = \{A \text{ se réalise et } B \text{ se réalise}\}$ (parfois noté AB)

— $A^c = \{A \text{ ne se réalise pas}\}$ (aussi noté $\bar{A}$ ou $\Omega \setminus A$)

Définition 1.6 (Mesure de probabilité (approche intuitive)). Une **mesure de probabilité** est une application $P: \mathcal{A} \rightarrow [0, 1]$, où $\mathcal{A}$ est l'ensemble des événements (souvent $\mathcal{A} = \mathcal{P}(\Omega)$, l'ensemble des parties de Ω). $P(A)$ est « la probabilité de A », c'est la chance que A soit réalisé au cours de l'expérience.

Exemple 1.7 (Cas d'équiprobabilité sur un univers fini). Lancer d'un dé : $\Omega = \{1, 2, 3, 4, 5, 6\}$ et $\mathcal{A} = \mathcal{P}(\Omega)$. Si tous les résultats élémentaires sont équiprobables, alors pour tout événement $A \subseteq \Omega$:

$$P(A) = \frac{\text{Card}(A)}{\text{Card}(\Omega)}$$

(où $\text{Card}(A)$ désigne le cardinal de A , c'est-à-dire le nombre d'éléments dans A).

1.2 Interprétation fréquentiste et équiprobabilité

Le triplet $(\Omega, \mathcal{A}, P)$ (ou $(\Omega, \mathcal{F}, \mathbb{P})$) avec $\mathcal{F}$ une **tribu** sur Ω constitue un *espace probabilisé*.

- Ω : univers des possibles
- $\mathcal{A}$ (ou $\mathcal{F}$) : ensemble des événements (une tribu sur Ω)
- P (ou $\mathbb{P}$) : mesure de probabilité

On peut répéter N fois une expérience de façon indépendante. Soit N_A le nombre de fois où l'événement A est réalisé. La fréquence d'apparition de A est $P_N(A) = \frac{N_A}{N}$. L'interprétation fréquentiste de la probabilité est :

$$P(A) = \lim_{N \rightarrow \infty} P_N(A)$$

Remarque 1.8. On ne va pas utiliser cela comme définition formelle de la probabilité à ce stade, car la notion de limite de fréquences empiriques nécessite elle-même une formalisation (via la loi des grands nombres). C'est plutôt une interprétation intuitive et une motivation historique importante.

Proposition 1.9 (Cas d'équiprobabilité). Si Ω est fini et tous les résultats (événements élémentaires) sont équiprobables, alors pour tout événement $A \subseteq \Omega$:

$$P(A) = \frac{\text{Card}(A)}{\text{Card}(\Omega)} = \frac{\text{nombre de cas favorables à } A}{\text{nombre de cas possibles}}$$

1.3 Analyse Combinatoire

L'analyse combinatoire est l'art de compter les éléments d'ensembles finis. Elle est cruciale pour calculer des probabilités dans le cas d'équiprobabilité.

1.3.1 Principe du dénombrement (ou principe multiplicatif)

Supposons qu'on ait une suite de k expériences $E_1, E_2, \dots, E_k$. Si l'expérience E_i a n_i résultats possibles (pour $i = 1, \dots, k$), et que les choix pour chaque expérience sont indépendants les uns des autres, alors la séquence complète d'expériences $(E_1, E_2, \dots, E_k)$ a $n_1 \times n_2 \times \dots \times n_k$ résultats possibles.

Exemple 1.10. J'ai :

- 3 pantalons différents
- 5 pulls différents
- 4 T-shirts différents

Le nombre de façons de m'habiller (en choisissant un pantalon, un pull et un T-shirt) est $3 \times 5 \times 4 = 60$.

1.3.2 Permutations

Définition 1.11 (Factorielle). Pour un entier naturel $n \in \mathbb{N}$, la factorielle de n , notée $n!$, est définie par :

$$n! = n \times (n-1) \times (n-2) \times \cdots \times 2 \times 1 \quad \text{pour } n \geq 1$$

Par convention, pour $n = 0$, on définit $0! = 1$.

Proposition 1.12. $n!$ est le nombre de **permutations** (c'est-à-dire d'arrangements ordonnés) d'un ensemble de n éléments distincts. C'est le nombre de façons d'ordonner ces n éléments.

Exemple 1.13. Soit l'ensemble $E = \{1, 2, 3\}$. Le nombre de permutations des éléments de E est $3! = 3 \times 2 \times 1 = 6$. Ces permutations sont : $(1, 2, 3)$, $(1, 3, 2)$, $(2, 1, 3)$, $(2, 3, 1)$, $(3, 1, 2)$, et $(3, 2, 1)$. (Ici, (a, b, c) représente un ordre des éléments.)

1.3.3 Arrangements et Combinaisons (Nombre de sous-ensembles)

Définition 1.14 (Arrangement sans répétition). Un **arrangement** de k éléments choisis parmi n éléments distincts (avec $k \leq n$) est une sélection **ordonnée** de k éléments. L'ordre dans lequel les éléments sont choisis est important. Le nombre d'arrangements de k éléments parmi n , noté A_n^k (parfois $P(n, k)$ ou P_n^k), est :

$$A_n^k = n \times (n-1) \times \cdots \times (n-k+1) = \frac{n!}{(n-k)!}$$

Définition 1.15 (Combinaison sans répétition). Une **combinaison** de k éléments choisis parmi n éléments distincts (avec $k \leq n$) est une sélection **non ordonnée** de k éléments. C'est-à-dire un sous-ensemble de k éléments, où l'ordre de sélection n'a pas d'importance. Le nombre de combinaisons de k éléments parmi n est noté $\binom{n}{k}$.

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

(Appellation courante : " k parmi n " ou " n choose k ")

Proposition 1.16. Le nombre $\binom{n}{k}$ est le nombre de sous-ensembles distincts de k éléments que l'on peut former à partir d'un ensemble de n éléments distincts.

Démonstration. Pour former un sous-ensemble ordonné de k éléments (un arrangement), on a :

- n choix pour le 1^{er} élément.
- $(n-1)$ choix pour le 2^{ème} élément (puisque'il doit être distinct du premier).
- ...
- $(n-k+1)$ choix pour le $k^{\text{ième}}$ élément.

Par le principe multiplicatif, il y a $n(n-1)\cdots(n-k+1) = A_n^k$ façons de choisir k éléments de manière ordonnée. Cependant, pour les combinaisons (sous-ensembles), l'ordre des k éléments choisis n'a pas d'importance. Par exemple, si $n = 3, k = 2$, choisir $\{1, 2\}$ est le même sous-ensemble que choisir $\{2, 1\}$. Chaque sous-ensemble de k éléments peut être ordonné de $k!$

manières différentes (c'est le nombre de permutations de ces k éléments). Donc, en comptant les A_n^k arrangements, on a compté $k!$ fois chaque sous-ensemble unique de k éléments. Pour obtenir le nombre de combinaisons, on divise le nombre d'arrangements par $k!$:

$$\binom{n}{k} = \frac{A_n^k}{k!} = \frac{n(n-1)(n-2)\dots(n-k+1)}{k!} = \frac{n!}{k!(n-k)!}$$

□

1.3.4 Modèles classiques d'urnes

Considérons n urnes discernables (par exemple, numérotées) et k boules à y placer.

	Boules identiques	Boules différentes
Max 1 boule par urne $(k \leq n)$	$\binom{n}{k} \quad (1)$ (Choix de k urnes parmi n)	$A_n^k = \frac{n!}{(n-k)!} \quad (2)$ (Nombre de manières de placer k boules distinctes dans n urnes distinctes, avec au plus une boule par urne)
Pas de contrainte d'occupation par urne	$\binom{n+k-1}{k} \quad (4)$ (Combinaisons avec répétition)	$n^k \quad (3)$ (Arrangements avec répétition : chaque boule a n choix d'urnes)

Preuves des modèles d'urnes

Preuve du cas (1) : Max 1 boule par urne, boules identiques *Contexte : Placer k boules identiques dans n urnes discernables, avec au plus une boule par urne.* Comme les boules sont identiques, la seule chose qui distingue un placement d'un autre est l'ensemble des k urnes qui contiennent une boule. Il s'agit donc de choisir k urnes parmi n , sans tenir compte de l'ordre. Il y a $\binom{n}{k}$ possibilités.

Preuve du cas (2) : Max 1 boule par urne, boules différentes *Contexte : Placer k boules différentes dans n urnes discernables, avec au plus une boule par urne.* On choisit d'abord une urne pour la première boule (n choix), puis une urne pour la deuxième boule parmi les $n-1$ restantes $((n-1)$ choix), ..., et une urne pour la k -ième boule parmi les $n-k+1$ restantes. Cela revient à former un arrangement de k urnes choisies parmi n , où l'ordre importe car les boules sont distinctes. Le nombre de possibilités est $n(n-1)\dots(n-k+1) = A_n^k = \frac{n!}{(n-k)!}$.

Preuve du cas (3) : Pas de contrainte, boules différentes *Contexte : Placer k boules différentes dans n urnes discernables, sans contrainte sur le nombre de boules par urne.* Pour chaque boule (distincte), il y a n choix possibles d'urnes, et les choix pour chaque boule sont indépendants. Comme il y a k boules, le nombre total de possibilités est $n \times n \times \dots \times n$ (k fois)

$= n^k$. C'est le nombre d'arrangements avec répétition de k éléments pris dans un ensemble de taille n .

Preuve du cas (4) : Pas de contrainte, boules identiques (Combinaisons avec répétition) *Contexte : Placer k boules identiques dans n urnes discernables, sans contrainte sur le nombre de boules par urne.* C'est le problème classique des "étoiles et barres". On peut imaginer les k boules (identiques, représentées par des $\star$) et on a besoin de $n - 1$ séparateurs (barres, représentées par des $|$) pour les répartir dans les n urnes. Par exemple, si $n = 3$ urnes et $k = 4$ boules : $\star\star|\star|$ signifie 2 boules dans l'urne 1, 1 dans l'urne 2, et 1 dans l'urne 3. Nous avons un total de k étoiles et $n - 1$ barres, soit $k + (n - 1)$ positions au total. Le problème revient à choisir les k positions pour les étoiles (ou, de manière équivalente, les $n - 1$ positions pour les barres) parmi ces $k + n - 1$ positions. Le nombre de façons de le faire est $\binom{k+n-1}{k}$.

Exemple 1.17 (Application des modèles d'urnes). On a k boules et n urnes. On place les boules de façon à ce que la j -ième urne (U_j) ait au moins C_j boules (avec $C_j \geq 0$).

1. On place d'abord C_j boules dans l'urne U_j pour tout $j = 1, \dots, n$. Cela utilise $\sum_{j=1}^n C_j$ boules.
2. Il reste $k' = k - \sum_{j=1}^n C_j$ boules à placer dans les n urnes sans autre contrainte. (On suppose $k' \geq 0$, sinon le problème n'a pas de solution).

Si les boules sont identiques, le nombre de façons de placer les k' boules restantes dans les n urnes est (d'après le cas (4) précédent, avec k' boules et n urnes) :

$$\binom{n+k'-1}{k'} = \binom{n + \left(k - \sum_{j=1}^n C_j\right) - 1}{k - \sum_{j=1}^n C_j}$$

ou de manière équivalente $\binom{n+k'-1}{n-1}$.

Exemple 1.18 (Autre formulation : k boules noires, l boules rouges). On a k boules noires et l boules rouges. On les place dans n urnes, avec au plus une boule par urne. (On suppose $k + l \leq n$).

1. On place d'abord les k boules noires : Si les boules noires sont indiscernables, il y a $\binom{n}{k}$ façons de choisir les urnes pour elles.
2. Il reste $n - k$ urnes vides. On place ensuite les l boules rouges dans ces $n - k$ urnes restantes : Si les boules rouges sont indiscernables, il y a $\binom{n-k}{l}$ façons.

Si les boules de même couleur sont indiscernables entre elles, mais les couleurs sont distinctes (et on se soucie de quelles urnes contiennent quelles couleurs), le nombre total de façons de placer les boules est $\binom{n}{k} \binom{n-k}{l}$.

1.3.5 Triangle de Pascal et Identité de Pascal

L'Identité de Pascal relie les coefficients binomiaux : Pour tous entiers naturels n, k tels que $1 \leq k \leq n - 1$:

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$$

Avec les conventions $\binom{n}{0} = 1$ et $\binom{n}{n} = 1$. Cette identité est à la base de la construction du **Triangle de Pascal**, où chaque terme est la somme des deux termes situés juste au-dessus de lui.

$$\begin{array}{ccccccc}
 & & & & 1 & & \\
 & & & 1 & & 1 & \\
 & & 1 & & 2 & & 1 \\
 & 1 & & 3 & & 3 & & 1 \\
 1 & & 4 & & 6 & & 4 & & 1 \\
 1 & & 5 & & 10 & & 10 & & 5 & & 1
 \end{array}$$

Remarque 1.19. La formule $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ est la définition générale, mais le Triangle de Pascal offre une méthode de calcul récursive pratique pour les petites valeurs de n .

1.3.6 Binôme de Newton

Le **Théorème du Binôme de Newton** donne le développement d'une puissance d'une somme : Pour tous $a, b \in \mathbb{R}$ (ou $\mathbb{C}$) et tout entier naturel $n \in \mathbb{N}$:

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$$

(On peut aussi écrire $a^{n-k}b^k$, l'important est que la somme des exposants de a et b soit n).

Exemple 1.20. Pour $n = 4$:

$$\begin{aligned}
 (a+b)^4 &= \binom{4}{0}a^0b^4 + \binom{4}{1}a^1b^3 + \binom{4}{2}a^2b^2 + \binom{4}{3}a^3b^1 + \binom{4}{4}a^4b^0 \\
 &= 1 \cdot b^4 + 4ab^3 + 6a^2b^2 + 4a^3b + 1 \cdot a^4 \\
 &= a^4 + 4a^3b + 6a^2b^2 + 4ab^3 + b^4
 \end{aligned}$$

Les coefficients 1, 4, 6, 4, 1 sont ceux de la ligne $n = 4$ du Triangle de Pascal.

Démonstration (esquisse). On développe le produit $(a+b)^n = (a+b)(a+b) \dots (a+b)$ (n facteurs). Chaque terme du développement est obtenu en choisissant a ou b dans chacun des n facteurs et en les multipliant. Un terme de la forme $a^k b^{n-k}$ est obtenu en choisissant k fois le terme a et $n-k$ fois le terme b parmi les n facteurs. Le nombre de façons de choisir les k facteurs qui fourniront un a (les $n-k$ autres fourniront un b) est précisément $\binom{n}{k}$. Ainsi, le coefficient du terme $a^k b^{n-k}$ dans le développement est $\binom{n}{k}$. $\square$

Exemple 1.21 (Conséquences du binôme de Newton). 1. En posant $a = 1, b = -1$: $(1 + (-1))^n = 0^n = \sum_{k=0}^n \binom{n}{k} (1)^k (-1)^{n-k}$. Si $n \geq 1$, $0^n = 0$, donc $\sum_{k=0}^n \binom{n}{k} (-1)^{n-k} = 0$. (Ou, de manière équivalente, $\sum_{k=0}^n \binom{n}{k} (-1)^k = 0$ si on utilise $a^{n-k}b^k$). Autrement dit : $\binom{n}{0} - \binom{n}{1} + \binom{n}{2} - \dots + (-1)^n \binom{n}{n} = 0$.

2. En posant $a = 1, b = 1 : (1 + 1)^n = 2^n = \sum_{k=0}^n \binom{n}{k} (1)^k (1)^{n-k} = \sum_{k=0}^n \binom{n}{k}$. Ceci signifie que la somme des éléments d'une ligne du Triangle de Pascal vaut 2^n . Cela correspond aussi au fait que $\sum_{k=0}^n \binom{n}{k}$ est le nombre total de sous-ensembles d'un ensemble à n éléments, qui est $\text{Card}(\mathcal{P}(E)) = 2^n$.

1.3.7 Combinatoire et Récursions

Certains problèmes de dénombrement peuvent être résolus à l'aide de relations de récurrence.

Exemple 1.22 (Guirlandes colorées). On veut former une guirlande de m boules. Les boules peuvent être Vertes (V), Violettes (T pour "mauve" comme dans "violet" en anglais, pour éviter le V), Rouges (R). Contraintes :

- Deux boules vertes ne peuvent pas être adjacentes (VV interdit).
- Deux boules violettes ne peuvent pas être adjacentes (TT interdit).

Soit X_m le nombre de guirlandes valides de longueur m . (*Note : La dérivation de la récurrence et des valeurs initiales dépend fortement du contexte non fourni ici, comme des notes originales. L'exemple est illustratif de la méthode matricielle pour une récurrence donnée*). Valeurs initiales (déterminées par inspection, ici on suppose qu'une guirlande d'une seule boule est valide si elle ne viole pas de contrainte par elle-même, ce qui est trivialement le cas, mais les contraintes portent sur des paires. Il faut définir plus précisément les 1eres valeurs). D'après les notes : $X_1 = 0$ $X_2 = 1$ $X_3 = 1$ $X_4 = 1$ $X_5 = 3$

La relation de récurrence est donnée dans les notes comme : $X_m = X_{m-2} + X_{m-3} + X_{m-5}$ pour $m \geq 5$.

On peut représenter cette récurrence linéaire à l'aide d'une matrice. Soit le vecteur d'état

$$y_m = \begin{pmatrix} X_m \\ X_{m-1} \\ X_{m-2} \\ X_{m-3} \\ X_{m-4} \end{pmatrix}. \text{ Alors } y_m = M y_{m-1} \text{ avec la matrice } M :$$

$$M = \begin{pmatrix} 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

Si l'on connaît le vecteur d'état initial y_s pour un certain indice s (par exemple $s = 5$), on peut trouver y_m pour $m > s$ par :

$$y_m = M^{m-s} y_s$$

$$\text{Pour } s = 5, y_5 = \begin{pmatrix} X_5 \\ X_4 \\ X_3 \\ X_2 \\ X_1 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \\ 1 \\ 1 \\ 0 \end{pmatrix}.$$

Remarque 1.23. La résolution de relations de récurrence linéaires comme $X_m = c_1 X_{m-1} + \dots + c_d X_{m-d}$ passe souvent par la recherche des racines du polynôme caractéristique $r^d - c_1 r^{d-1} - \dots - c_d = 0$. La solution générale est une combinaison linéaire de termes r_i^m (ou $m^j r_i^m$ en cas de racines multiples). La formulation matricielle est une autre approche, utile pour le calcul itératif et l'analyse de la stabilité.

1.4 Exemple : Paradoxe des anniversaires

Problème : Dans un groupe de m personnes, quelle est la probabilité qu'au moins deux personnes partagent le même jour d'anniversaire ? Hypothèses :

- Une année compte 365 jours (on ignore les années bissextiles).
- Les naissances sont réparties uniformément tout au long de l'année (chaque jour est équiprobable pour un anniversaire).
- On s'intéresse au cas $2 \leq m \leq 365$.

Il est plus simple de calculer la probabilité de l'événement complémentaire $A^c = \{\text{toutes les } m \text{ personnes ont des anniversaires différents}\}$. Ensuite, $P(\text{au moins deux mêmes anniversaires}) = 1 - P(A^c)$.

- **Nombre de cas possibles** ($\text{Card}(\Omega)$) : Chaque personne peut avoir son anniversaire l'un des 365 jours. Les choix sont indépendants et avec remise (deux personnes peuvent avoir le même anniversaire). Il y a m personnes. $\text{Card}(\Omega) = 365 \times 365 \times \dots \times 365$ (m fois) $= 365^m$.
- **Nombre de cas favorables à A^c** ($\text{Card}(A^c)$) : La première personne a 365 choix. La deuxième personne doit avoir un anniversaire différent (364 choix restants). La m -ième personne doit avoir un anniversaire différent des $m-1$ précédents ($365 - (m-1)$ choix). Donc, $\text{Card}(A^c) = 365 \times 364 \times \dots \times (365 - m + 1) = A_{365}^m = \frac{365!}{(365-m)!}$.

En supposant l'équiprobabilité des configurations d'anniversaires :

$$P(A^c) = \frac{\text{Card}(A^c)}{\text{Card}(\Omega)} = \frac{A_{365}^m}{365^m} = \frac{365!}{(365-m)! \cdot 365^m}$$

Donc, la probabilité qu'au moins deux personnes aient le même anniversaire est :

$$P(\text{au moins deux mêmes anniversaires}) = 1 - \frac{365!}{(365-m)! \cdot 365^m}$$

Tableau de valeurs (approximatives) :

m (nombre de personnes)	5	20	23	30	50
Probabilité (approx.)	0,027	0,411	0,507	0,706	0,970

(Note : Pour $m = 23$, la probabilité dépasse 50%.)

1.5 Axiomatique des Probabilités (Kolmogorov)

L'approche moderne des probabilités repose sur une base axiomatique solide, principalement due à Andreï Kolmogorov (1933).

Définition 1.24 (Espace Probabilisé). Un **espace probabilisé** est un triplet $(\Omega, \mathcal{F}, P)$ où :

1. Ω est un ensemble quelconque, appelé l'**univers** ou l'ensemble des résultats possibles (ou issues élémentaires) de l'expérience aléatoire.
2. $\mathcal{F}$ (parfois noté $\mathcal{A}$ dans tes notes) est une **tribu** (ou **σ -algèbre**) sur Ω . C'est une collection de sous-ensembles de Ω (appelés **événements**) satisfaisant les propriétés suivantes :
 - (a) $\Omega \in \mathcal{F}$ (l'univers est un événement).
 - (b) Si $A \in \mathcal{F}$, alors son complémentaire $A^c = \Omega \setminus A$ est aussi dans $\mathcal{F}$ (la tribu est stable par passage au complémentaire).
 - (c) Si $(A_i)_{i \in \mathbb{N}}$ est une suite (finie ou dénombrable) d'événements $A_i \in \mathcal{F}$, alors leur union $\bigcup_{i=1}^{\infty} A_i$ est aussi dans $\mathcal{F}$ (la tribu est stable par union dénombrable).

Explication : $\mathcal{F}$ représente l'ensemble des événements auxquels on peut attribuer une probabilité. Il contient toutes les combinaisons "raisonnables" d'événements élémentaires que l'on peut former (unions, intersections, complémentaires).

3. P (ou $\mathbb{P}$) est une **mesure de probabilité** sur $(\Omega, \mathcal{F})$. C'est une application $P : \mathcal{F} \rightarrow [0, 1]$ satisfaisant les axiomes suivants :
 - (a) **Non-négativité** : Pour tout événement $A \in \mathcal{F}$, $P(A) \geq 0$. (Automatiquement inclus dans $P : \mathcal{F} \rightarrow [0, 1]$).
 - (b) **Normalisation** : $P(\Omega) = 1$ (la probabilité de l'événement certain est 1).
 - (c) **σ -additivité** (ou additivité dénombrable) : Pour toute suite $(A_i)_{i \in \mathbb{N}}$ d'événements **mutuellement exclusifs** (ou **disjoints deux à deux**, i.e., $A_i \cap A_j = \emptyset$ pour $i \neq j$), on a :


$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Proposition 1.25 (Propriétés élémentaires d'une tribu). De la définition d'une tribu $\mathcal{F}$, on peut déduire :

1. $\emptyset \in \mathcal{F}$ (l'événement impossible est dans la tribu, car $\emptyset = \Omega^c$).
2. Si $A_1, A_2, \dots, A_n$ est une suite finie d'événements dans $\mathcal{F}$, alors $\bigcup_{i=1}^n A_i \in \mathcal{F}$ (stabilité par union finie).
3. Si $(A_i)_{i \in \mathbb{N}}$ est une suite (finie ou dénombrable) d'événements dans $\mathcal{F}$, alors leur intersection $\bigcap_{i=1}^{\infty} A_i \in \mathcal{F}$ (stabilité par intersection dénombrable, par les lois de De Morgan : $\bigcap A_i = (\bigcup A_i^c)^c$).
4. Si $A, B \in \mathcal{F}$, alors $A \setminus B = A \cap B^c \in \mathcal{F}$ (différence ensembliste).
5. Si $A, B \in \mathcal{F}$, alors $A \Delta B = (A \setminus B) \cup (B \setminus A) \in \mathcal{F}$ (différence symétrique).

Remarque 1.26 (σ -algèbre vs Algèbre). Une **algèbre** d'ensembles satisfait les mêmes conditions qu'une σ -algèbre, mais la condition (c) de stabilité par union est requise seulement pour les unions *finies*. Une σ -algèbre est donc une algèbre qui est en plus stable par union *dénombrable*.

Remarque 1.27 (La mesure de probabilité : Explication). $P(A)$ est la probabilité que l'événement A se réalise. La σ -additivité est cruciale : elle permet de calculer la probabilité d'événements complexes (unions dénombrables) à partir de probabilités d'événements plus simples (disjoints), et elle assure la cohérence des probabilités.



$$A \Delta B = (A \setminus B) \cup (B \setminus A) \text{ avec } A \setminus B = A \cap B^c$$

FIGURE 1 – Diagramme de Venn illustrant A , B , $A \setminus B$, $B \setminus A$, et $A \cap B$

Proposition 1.28 (Propriétés d'une mesure de probabilité). Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé.

1. $P(\emptyset) = 0$.

Démonstration. Puisque Ω et $\emptyset$ sont disjoints et $\Omega \cup \emptyset = \Omega$. Par additivité (ii) de la mesure de probabilité pour deux événements disjoints (cas particulier de la σ -additivité) : $P(\Omega \cup \emptyset) = P(\Omega) + P(\emptyset)$. Donc $P(\Omega) = P(\Omega) + P(\emptyset)$. Comme $P(\Omega) = 1$ (et est donc fini), on peut soustraire $P(\Omega)$ des deux côtés, ce qui implique $P(\emptyset) = 0$. $\square$

2. **Additivité finie :** Pour une suite finie $A_1, \dots, A_n$ d'événements disjoints deux à deux, $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$.
3. $P(A^c) = 1 - P(A)$.

Démonstration. A et A^c sont disjoints et $A \cup A^c = \Omega$. Donc $P(A \cup A^c) = P(A) + P(A^c)$. $P(\Omega) = P(A) + P(A^c)$. $1 = P(A) + P(A^c)$, d'où $P(A^c) = 1 - P(A)$. $\square$

4. **Monotonie :** Si $A \subseteq B$ (où $A, B \in \mathcal{F}$), alors $P(A) \leq P(B)$.

Démonstration. On peut écrire $B = A \cup (B \setminus A)$. Les événements A et $B \setminus A$ (aussi noté $B \cap A^c$) sont disjoints. Donc $P(B) = P(A) + P(B \setminus A)$. Comme $P(B \setminus A) \geq 0$, on a $P(B) \geq P(A)$. $\square$




FIGURE 2 – Illustration pour $P(A) \leq P(B)$ si $A \subseteq B$

5. $P(A \setminus B) = P(A \cap B^c) = P(A) - P(A \cap B)$.

Démonstration. On a $A = (A \cap B) \cup (A \cap B^c)$, et ces deux événements sont disjoints. Donc $P(A) = P(A \cap B) + P(A \cap B^c)$. D'où $P(A \cap B^c) = P(A) - P(A \cap B)$. $\square$

6. **Formule de Poincaré (ou principe d'inclusion-exclusion) pour deux événements :**

Pour tous événements $A, B \in \mathcal{F}$:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Démonstration. $A \cup B = A \cup (B \setminus A) = A \cup (B \cap A^c)$. Ces deux ensembles sont disjoints. Donc $P(A \cup B) = P(A) + P(B \cap A^c)$. En utilisant la propriété précédente $P(B \cap A^c) = P(B) - P(B \cap A)$, on obtient : $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. $\square$




FIGURE 3 – Illustration pour $P(A \cup B)$

7. **Sous-additivité (Inégalité de Boole) :** Pour toute suite (finie ou dénombrable) d'événements $(A_i)_{i \in I}$ (pas nécessairement disjoints) :

$$P\left(\bigcup_{i \in I} A_i\right) \leq \sum_{i \in I} P(A_i)$$

Remarque 1.29 (Principe d'inclusion-exclusion généralisé). Pour n événements $A_1, \dots, A_n$:

$$\begin{aligned} P\left(\bigcup_{i=1}^n A_i\right) &= \sum_i P(A_i) - \sum_{i < j} P(A_i \cap A_j) + \sum_{i < j < k} P(A_i \cap A_j \cap A_k) \\ &\quad - \dots + (-1)^{n-1} P(A_1 \cap A_2 \cap \dots \cap A_n) \end{aligned}$$

Par exemple, pour trois événements A, B, C : $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$.




FIGURE 4 – Illustration pour $P(A \cup B \cup C)$

1.6 Probabilités Conditionnelles et Indépendance

Définition 1.30 (Probabilité Conditionnelle). Soient $(\Omega, \mathcal{F}, P)$ un espace probabilisé, et $A, B \in \mathcal{F}$ deux événements. Si $P(B) > 0$, la **probabilité conditionnelle** de A sachant (ou étant donné) que B est réalisé, notée $P(A|B)$, est définie par :

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Interprétation : $P(A|B)$ est la probabilité que l'événement A se réalise, sachant que l'événement B s'est déjà produit. L'univers des possibles est "réduit" à B , et on "renormalise" la mesure de probabilité pour que $P(B|B) = 1$. Comme illustré sur la figure 5, $P(A|B)$ est la proportion de l'événement B qui est aussi dans A .




FIGURE 5 – Illustration de la probabilité conditionnelle $P(A|B)$

Remarque 1.31. — $P(A, B)$ est une notation courante pour $P(A \cap B)$ que tu utilises dans tes notes.

— Pour un B fixé tel que $P(B) > 0$, l'application $Q_B : A \mapsto P(A|B)$ est elle-même une mesure de probabilité sur $(\Omega, \mathcal{F})$ (ou plus précisément sur $(B, \mathcal{F}_B)$ où $\mathcal{F}_B = \{A \cap B \mid A \in \mathcal{F}\}$).

Exemple 1.32. On lance un dé équilibré. Soit $A = \{\text{obtenir un 4}\}$ et $B = \{\text{obtenir un nombre pair}\}$. $\Omega = \{1, 2, 3, 4, 5, 6\}$. $A = \{4\}$, $B = \{2, 4, 6\}$. $P(A) = 1/6$, $P(B) = 3/6 = 1/2$. $A \cap B = \{4\} \cap \{2, 4, 6\} = \{4\}$. Donc $P(A \cap B) = P(\{4\}) = 1/6$. Alors $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{1/6}{1/2} = \frac{1}{6} \times \frac{2}{1} = \frac{2}{6} = \frac{1}{3}$. Intuitivement, si on sait que le résultat est pair (donc dans $\{2, 4, 6\}$), il y a une chance sur trois que ce soit un 4.

Proposition 1.33 (Formule des probabilités composées). De la définition de la probabilité conditionnelle, on tire directement : $P(A \cap B) = P(A|B)P(B)$ (si $P(B) > 0$). Et symétriquement, $P(A \cap B) = P(B|A)P(A)$ (si $P(A) > 0$). Cette formule se généralise à plus de deux événements. Par exemple, pour trois événements A, B, C : $P(A \cap B \cap C) = P(A|B \cap C)P(B|C)P(C)$ (si $P(B \cap C) > 0$ et $P(C) > 0$).

Proposition 1.34 (Théorème des probabilités totales (ou formule des probabilités totales)). Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. Soit $(A_i)_{i \in I}$ une **partition** de Ω , c'est-à-dire une collection (finie ou dénombrable) d'événements $A_i \in \mathcal{F}$ telle que :

— Les A_i sont disjoints deux à deux : $A_i \cap A_j = \emptyset$ pour $i \neq j$.

- Leur union recouvre Ω : $\bigcup_{i \in I} A_i = \Omega$.
- $P(A_i) > 0$ pour tout $i \in I$ (nécessaire pour définir les probabilités conditionnelles).

Alors, pour tout événement $B \in \mathcal{F}$:

$$P(B) = \sum_{i \in I} P(B|A_i)P(A_i)$$

Démonstration. L'événement B peut s'écrire $B = B \cap \Omega = B \cap (\bigcup_{i \in I} A_i) = \bigcup_{i \in I} (B \cap A_i)$. Les événements $(B \cap A_i)$ sont disjoints deux à deux (car les A_i le sont). Par σ -additivité de P :

$$P(B) = P\left(\bigcup_{i \in I} (B \cap A_i)\right) = \sum_{i \in I} P(B \cap A_i)$$

En utilisant la formule des probabilités composées $P(B \cap A_i) = P(B|A_i)P(A_i)$ (puisque $P(A_i) > 0$), on obtient :

$$P(B) = \sum_{i \in I} P(B|A_i)P(A_i)$$

□

Exemple 1.35 (Test de dépistage). Un test de dépistage pour une maladie. $M = \{\text{la personne est malade}\}$, $M^c = \{\text{la personne est saine}\}$. $T^+ = \{\text{le test est positif}\}$, $T^- = \{\text{le test est négatif}\}$. Données :

- $P(M) = 0.01$ (prévalence de la maladie : 1%). Donc $P(M^c) = 0.99$.
- $P(T^+|M) = 0.95$ (sensibilité du test : proba d'être positif si malade).
- $P(T^+|M^c) = 0.02$ (proba de faux positif : proba d'être positif si sain). (Implique $P(T^-|M^c) = 0.98$, spécificité).

Quelle est la probabilité qu'une personne testée au hasard ait un test positif, $P(T^+)$? La partition est $\{M, M^c\}$. Par la formule des probabilités totales :

$$\begin{aligned} P(T^+) &= P(T^+|M)P(M) + P(T^+|M^c)P(M^c) \\ &= (0.95)(0.01) + (0.02)(0.99) \\ &= 0.0095 + 0.0198 = 0.0293 \end{aligned}$$

La probabilité d'avoir un test positif est de 2.93%.

Proposition 1.36 (Formule de Bayes (ou Théorème de Bayes)). Soit $(A_i)_{i \in I}$ une partition de Ω (avec $P(A_i) > 0$). Soit $B \in \mathcal{F}$ un événement tel que $P(B) > 0$. Alors, pour tout $j \in I$:

$$P(A_j|B) = \frac{P(B|A_j)P(A_j)}{P(B)} = \frac{P(B|A_j)P(A_j)}{\sum_{i \in I} P(B|A_i)P(A_i)}$$

Cette formule permet de "renverser" les conditionnements : calculer $P(A_j|B)$ à partir des $P(B|A_i)$.

Démonstration. Par définition de la probabilité conditionnelle : $P(A_j|B) = \frac{P(A_j \cap B)}{P(B)}$. Par la formule des probabilités composées : $P(A_j \cap B) = P(B|A_j)P(A_j)$. En substituant cela dans la formule ci-dessus, et en utilisant la formule des probabilités totales pour $P(B)$ au dénominateur, on obtient le résultat. □

Exemple 1.37 (Suite du test de dépistage). Quelle est la probabilité qu'une personne soit malade sachant que son test est positif, $P(M|T^+)$? En utilisant la formule de Bayes (avec $A_1 = M$, $A_2 = M^c$ et $B = T^+$) :

$$\begin{aligned} P(M|T^+) &= \frac{P(T^+|M)P(M)}{P(T^+)} \\ &= \frac{(0.95)(0.01)}{0.0293} \approx \frac{0.0095}{0.0293} \approx 0.324 \end{aligned}$$

Même si le test est positif, la probabilité que la personne soit réellement malade n'est que de 32.4%. Cela est dû à la faible prévalence de la maladie et au taux de faux positifs.

Exemple 1.38 (Problème de Monty Hall). Trois portes. Derrière une porte, il y a une voiture ; derrière les deux autres, des chèvres.

1. Le joueur choisit une porte (disons, porte 1).
2. L'animateur (Monty Hall), qui sait où est la voiture, ouvre une autre porte (disons, porte 3) qui cache une chèvre.
3. L'animateur propose au joueur de changer son choix initial (passer de la porte 1 à la porte 2).

Le joueur a-t-il intérêt à changer ? Soient les événements : $C_i = \{\text{la voiture est derrière la porte } i\}$, pour $i = 1, 2, 3$. On suppose $P(C_1) = P(C_2) = P(C_3) = 1/3$. $J_1 = \{\text{le joueur choisit initialement la porte 1}\}$. $M_3 = \{\text{Monty ouvre la porte 3 (révélant une chèvre)}\}$.

On veut comparer $P(C_1|M_3)$ (probabilité que la voiture soit derrière la porte 1 sachant que Monty a ouvert la porte 3) avec $P(C_2|M_3)$.

- $P(M_3|C_1)$: Si la voiture est en 1 (et que le joueur a choisi 1), Monty peut ouvrir la porte 2 ou la porte 3 (avec une chèvre). On suppose qu'il choisit au hasard entre les deux : $P(M_3|C_1) = 1/2$.
- $P(M_3|C_2)$: Si la voiture est en 2 (et que le joueur a choisi 1), Monty *doit* ouvrir la porte 3 (la seule autre porte avec une chèvre). $P(M_3|C_2) = 1$.
- $P(M_3|C_3)$: Si la voiture est en 3 (et que le joueur a choisi 1), Monty ne peut pas ouvrir la porte 3. Donc $P(M_3|C_3) = 0$.

Calculons $P(M_3)$ par la formule des probabilités totales (conditionnant sur C_1, C_2, C_3) : $P(M_3) = P(M_3|C_1)P(C_1) + P(M_3|C_2)P(C_2) + P(M_3|C_3)P(C_3)$ $P(M_3) = (1/2)(1/3) + (1)(1/3) + (0)(1/3) = 1/6 + 1/3 = 1/6 + 2/6 = 3/6 = 1/2$.

Maintenant, par la formule de Bayes : $P(C_1|M_3) = \frac{P(M_3|C_1)P(C_1)}{P(M_3)} = \frac{(1/2)(1/3)}{1/2} = 1/3$. $P(C_2|M_3) = \frac{P(M_3|C_2)P(C_2)}{P(M_3)} = \frac{(1)(1/3)}{1/2} = 2/3$. $P(C_3|M_3) = \frac{P(M_3|C_3)P(C_3)}{P(M_3)} = \frac{(0)(1/3)}{1/2} = 0$ (ce qui est logique).

La probabilité que la voiture soit derrière la porte initialement choisie (porte 1) reste $1/3$. La probabilité qu'elle soit derrière l'autre porte non ouverte (porte 2) est $2/3$. Il est donc avantageux de changer de porte.

Définition 1.39 (Indépendance de deux événements). Deux événements A et B sont dits **indépendants** si la réalisation de l'un n'affecte pas la probabilité de réalisation de l'autre.

Formellement :

$$P(A \cap B) = P(A)P(B)$$

Si $P(B) > 0$, cela est équivalent à $P(A|B) = P(A)$. Si $P(A) > 0$, cela est équivalent à $P(B|A) = P(B)$.

Exemple 1.40. On lance deux pièces équilibrées. $A = \{\text{le 1er lancer est Pile}\}$. $P(A) = 1/2$. $B = \{\text{le 2ème lancer est Pile}\}$. $P(B) = 1/2$. $A \cap B = \{\text{les deux lancers sont Pile}\}$. $P(A \cap B) = 1/4$. Puisque $P(A \cap B) = (1/2)(1/2) = P(A)P(B)$, les événements A et B sont indépendants.

Soit $C = \{\text{obtenir au moins une Pile}\}$. $\Omega = \{(P, P), (P, F), (F, P), (F, F)\}$. $C = \{(P, P), (P, F), (F, P)\}$. $P(C) = 3/4$. $A \cap C = \{\text{1er lancer Pile ET au moins une Pile}\} = \{\text{1er lancer Pile}\} = A$. $P(A \cap C) = P(A) = 1/2$. $P(A)P(C) = (1/2)(3/4) = 3/8$. Comme $P(A \cap C) = 1/2 \neq 3/8 = P(A)P(C)$, les événements A et C ne sont **pas** indépendants.

Définition 1.41 (Indépendance mutuelle de plusieurs événements). Une collection d'événements $(A_i)_{i \in I}$ (où I est un ensemble d'indices) est dite **mutuellement indépendante** si pour toute sous-collection finie d'événements distincts $A_{j_1}, A_{j_2}, \dots, A_{j_k}$ de cette collection :

$$P(A_{j_1} \cap A_{j_2} \cap \dots \cap A_{j_k}) = P(A_{j_1})P(A_{j_2}) \dots P(A_{j_k})$$

Remarque 1.42. L'indépendance deux à deux (i.e., $P(A_i \cap A_j) = P(A_i)P(A_j)$ pour tous $i \neq j$) n'est **pas** suffisante pour garantir l'indépendance mutuelle si la collection contient plus de deux événements. L'indépendance mutuelle est une condition plus forte.

Exemple 1.43 (Indépendance deux à deux mais pas mutuelle (Exemple de Bernstein)).

On lance deux dés équilibrés. $A = \{\text{le 1er dé donne un nombre impair}\}$. $P(A) = 1/2$. $B = \{\text{le 2ème dé donne un nombre impair}\}$. $P(B) = 1/2$. $C = \{\text{la somme des deux dés est impaire}\}$. Pour que la somme soit impaire, un dé doit être pair et l'autre impair. $C = (A \cap B^c) \cup (A^c \cap B)$. $P(C) = P(A \cap B^c) + P(A^c \cap B)$ (car disjoints). Comme les lancers sont indépendants, $P(A \cap B^c) = P(A)P(B^c) = (1/2)(1/2) = 1/4$. De même, $P(A^c \cap B) = P(A^c)P(B) = (1/2)(1/2) = 1/4$. Donc $P(C) = 1/4 + 1/4 = 1/2$.

Vérifions l'indépendance deux à deux :

- $A \cap B = \{\text{1er impair, 2ème impair}\}$. $P(A \cap B) = P(A)P(B) = (1/2)(1/2) = 1/4$. Donc $A \perp\!\!\!\perp B$.
- $A \cap C = \{\text{1er impair ET somme impaire}\}$. Si le 1er est impair, pour que la somme soit impaire, le 2ème doit être pair (B^c). Donc $A \cap C = A \cap B^c$. $P(A \cap C) = P(A \cap B^c) = P(A)P(B^c) = (1/2)(1/2) = 1/4$. Et $P(A)P(C) = (1/2)(1/2) = 1/4$. Donc $A \perp\!\!\!\perp C$.
- $B \cap C = \{\text{2ème impair ET somme impaire}\}$. Si le 2ème est impair, pour que la somme soit impaire, le 1er doit être pair (A^c). Donc $B \cap C = A^c \cap B$. $P(B \cap C) = P(A^c \cap B) = P(A^c)P(B) = (1/2)(1/2) = 1/4$. Et $P(B)P(C) = (1/2)(1/2) = 1/4$. Donc $B \perp\!\!\!\perp C$.

Les événements A, B, C sont indépendants deux à deux.

Sont-ils mutuellement indépendants ? Regardons $P(A \cap B \cap C)$. $A \cap B \cap C = \{\text{1er impair, 2ème impair ET somme impaire}\}$. Si le 1er est impair et le 2ème est impair, alors leur somme est paire. Donc l'événement "somme impaire" (C) ne peut pas se produire. Ainsi, $A \cap B \cap C = \emptyset$, et $P(A \cap B \cap C) = P(\emptyset) = 0$.

Cependant, $P(A)P(B)P(C) = (1/2)(1/2)(1/2) = 1/8$. Puisque $0 \neq 1/8$, les événements A, B, C ne sont **pas** mutuellement indépendants.

1.7 Suites d'Événements

Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. On considère une suite d'événements $(A_n)_{n \in \mathbb{N}}$, où $A_n \in \mathcal{F}$ pour tout $n \geq 1$.

Définition 1.44 (Suite croissante et décroissante d'événements). — La suite $(A_n)_{n \in \mathbb{N}}$ est dite **croissante** si $A_n \subseteq A_{n+1}$ pour tout $n \geq 1$. Dans ce cas, la **limite** de la suite est définie par $\lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n$. Cet événement limite appartient à $\mathcal{F}$ (car $\mathcal{F}$ est une σ -algèbre).
— La suite $(A_n)_{n \in \mathbb{N}}$ est dite **décroissante** si $A_{n+1} \subseteq A_n$ pour tout $n \geq 1$. Dans ce cas, la **limite** de la suite est définie par $\lim_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} A_n$. Cet événement limite appartient également à $\mathcal{F}$.




FIGURE 6 – Suite croissante d'événements
 $A_n \subseteq A_{n+1}$




FIGURE 7 – Suite décroissante d'événements
 $A_{n+1} \subseteq A_n$

Théorème 1.45 (Continuité de la mesure de probabilité). Si $(A_n)_{n \in \mathbb{N}}$ est une suite d'événements **monotone** (soit croissante, soit décroissante), alors :

$$P\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} P(A_n)$$

Démonstration. — **Cas d'une suite croissante** ($A_n \subseteq A_{n+1}$) : Soit $A = \lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n$. On définit une nouvelle suite d'événements disjoints $(B_n)_{n \geq 1}$: $B_1 = A_1$, $B_n = A_n \setminus A_{n-1}$ pour $n \geq 2$ (c'est la "couronne" entre A_{n-1} et A_n). Les B_n sont disjoints deux à deux et $\bigcup_{k=1}^n B_k = A_n$. De plus, $\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n = A$. Par σ -additivité de P : $P(A) = P(\bigcup_{n=1}^{\infty} B_n) = \sum_{n=1}^{\infty} P(B_n)$. Cette somme est la limite de ses sommes partielles : $P(A) = \lim_{N \rightarrow \infty} \sum_{n=1}^N P(B_n) = \lim_{N \rightarrow \infty} P\left(\bigcup_{n=1}^N B_n\right) = \lim_{N \rightarrow \infty} P(A_N)$.

— **Cas d'une suite décroissante** ($A_{n+1} \subseteq A_n$) : Soit $A = \lim_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} A_n$. Considérons la suite $(A_n^c)_{n \in \mathbb{N}}$. Si $A_{n+1} \subseteq A_n$, alors $A_n^c \subseteq A_{n+1}^c$. La suite (A_n^c) est donc croissante. Sa limite est $\bigcup_{n=1}^{\infty} A_n^c = (\bigcap_{n=1}^{\infty} A_n)^c = A^c$ (par les lois de De Morgan). En utilisant le résultat pour les suites croissantes : $P(A^c) = \lim_{n \rightarrow \infty} P(A_n^c)$. Puisque $P(A^c) = 1 - P(A)$ et $P(A_n^c) = 1 - P(A_n)$, on a : $1 - P(A) = \lim_{n \rightarrow \infty} (1 - P(A_n)) = 1 - \lim_{n \rightarrow \infty} P(A_n)$. Donc $P(A) = \lim_{n \rightarrow \infty} P(A_n)$.

□

Exemple 1.46 (Les urnes de minuit). Imaginez une série d'opérations à des instants $t_n = 1 - 1/n$ pour $n = 1, 2, \dots$ (temps approchant minuit).

- Minuit -1 ($t_1 = 0$) : On place 10 boules numérotées de 1 à 10 dans une urne, et on retire la boule $n^\circ 1$.
- Minuit $-1/2$ ($t_2 = 1/2$) : On ajoute 10 boules (11 à 20), on retire la boule $n^\circ 2$.
- Minuit $-1/k$ ($t_k = 1 - 1/k$) : On ajoute 10 boules ($10(k-1) + 1$ à $10k$), on retire la boule $n^\circ k$.

Combien de boules dans l'urne à minuit ? (*Note : La formulation de cet exemple peut prêter à confusion. Si, comme décrit, la boule k est retirée à l'étape k , alors toute boule m est retirée à l'étape m , donc l'urne est vide à minuit. Si le retrait est aléatoire, le résultat peut différer.*) A l'étape k , on ajoute 10 boules et on en retire 1. Le nombre de boules augmente de 9. Nombre de boules après k étapes : $9k$. Quand $k \rightarrow \infty$, le nombre de boules $\rightarrow \infty$.

Si la question est "La boule m est-elle dans l'urne à minuit ?", où m est un numéro fixe. La boule m est ajoutée à une certaine étape (si $10(k-1) < m \leq 10k$, elle est ajoutée à l'étape k). Elle est retirée à l'étape m . Donc, pour tout m fixé, la boule m n'est pas dans l'urne à minuit. L'urne est vide.

Définition 1.47 (Limite inférieure et limite supérieure d'une suite d'événements). Pour une suite quelconque d'événements $(A_n)_{n \in \mathbb{N}}$:

- La **limite inférieure** (liminf) est l'événement :

$$\liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k$$

$\liminf A_n$ est l'ensemble des $\omega \in \Omega$ qui appartiennent à tous les A_k à partir d'un certain rang n (dépendant de ω). On dit que les A_n se réalisent "finalement" ou "à partir d'un certain rang" (a.p.d.c.r.).

- La **limite supérieure** (limsup) est l'événement :

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$$

$\limsup A_n$ est l'ensemble des $\omega \in \Omega$ qui appartiennent à une infinité de A_k . On dit que les A_n se réalisent "infiniment souvent" (i.s.).

Ces deux événements limites sont toujours dans $\mathcal{F}$. On a toujours $\liminf A_n \subseteq \limsup A_n$. Si $\liminf A_n = \limsup A_n$, on dit que la suite (A_n) admet une limite, et cette limite commune est notée $\lim A_n$. (C'est le cas si la suite est monotone).

Théorème 1.48 (Lemmes de Borel-Cantelli). Soit $(A_n)_{n \in \mathbb{N}}$ une suite d'événements.

1. **Premier lemme de Borel-Cantelli** : Si la série des probabilités des A_n converge, i.e., $\sum_{n=1}^{\infty} P(A_n) < +\infty$, alors la probabilité que les A_n se réalisent infiniment souvent est nulle :

$$P(\limsup_{n \rightarrow \infty} A_n) = P(A_n \text{ i.s.}) = 0$$

2. Second lemme de Borel-Cantelli (ou lemme de Borel-Cantelli réciproque) : Si les événements $(A_n)_{n \in \mathbb{N}}$ sont **mutuellement indépendants** et si la série $\sum_{n=1}^{\infty} P(A_n)$ diverge (i.e., $= +\infty$), alors la probabilité que les A_n se réalisent infiniment souvent est un :

$$P(\limsup_{n \rightarrow \infty} A_n) = P(A_n \text{ i.s.}) = 1$$

Démonstration du premier lemme. Soit $L = \limsup A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$. Pour tout n , $L \subseteq \bigcup_{k=n}^{\infty} A_k$. Donc, $P(L) \leq P(\bigcup_{k=n}^{\infty} A_k)$. Par sous-additivité, $P(\bigcup_{k=n}^{\infty} A_k) \leq \sum_{k=n}^{\infty} P(A_k)$. Donc, $P(L) \leq \sum_{k=n}^{\infty} P(A_k)$ pour tout $n \geq 1$. Si $\sum_{n=1}^{\infty} P(A_n) < +\infty$, alors le reste de la série $\sum_{k=n}^{\infty} P(A_k)$ tend vers 0 lorsque $n \rightarrow \infty$. Puisque $P(L)$ est un nombre fixe (indépendant de n) et $P(L) \leq \text{reste}_n \rightarrow 0$, on doit avoir $P(L) = 0$. $\square$

Idée de la démonstration du second lemme (plus complexe). On considère l'événement complémentaire $(\limsup A_n)^c = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k^c$. On veut montrer que $P((\limsup A_n)^c) = 0$. $P(\bigcap_{k=n}^{\infty} A_k^c) = P(\lim_{N \rightarrow \infty} \bigcap_{k=n}^N A_k^c) = \lim_{N \rightarrow \infty} P(\bigcap_{k=n}^N A_k^c)$. Par indépendance des A_k , les A_k^c sont aussi indépendants. Donc $P(\bigcap_{k=n}^N A_k^c) = \prod_{k=n}^N P(A_k^c) = \prod_{k=n}^N (1 - P(A_k))$. En utilisant l'inégalité $1 - x \leq e^{-x}$ (pour $x \geq 0$), on a $(1 - P(A_k)) \leq e^{-P(A_k)}$. Donc $\prod_{k=n}^N (1 - P(A_k)) \leq \prod_{k=n}^N e^{-P(A_k)} = \exp\left(-\sum_{k=n}^N P(A_k)\right)$. Si $\sum P(A_k)$ diverge, alors $\sum_{k=n}^N P(A_k) \rightarrow \infty$ quand $N \rightarrow \infty$ (pour tout n fixe). Donc $\exp\left(-\sum_{k=n}^N P(A_k)\right) \rightarrow 0$ quand $N \rightarrow \infty$. Cela montre que $P(\bigcap_{k=n}^{\infty} A_k^c) = 0$ pour tout n . Alors $P((\limsup A_n)^c) = P(\bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k^c) \leq \sum_{n=1}^{\infty} P(\bigcap_{k=n}^{\infty} A_k^c) = \sum_{n=1}^{\infty} 0 = 0$. Donc $P(\limsup A_n) = 1$. $\square$

Exemple 1.49 (Jeu de Pile ou Face infini). On lance une pièce de monnaie une infinité de fois. Les lancers sont indépendants. Soit $A_n = \{\text{le } n\text{-ième lancer donne Pile}\}$.

- Si la pièce est truquée de telle sorte que $P(A_n) = P(\text{Pile au } n\text{-ième lancer}) = 1/n^2$. La série $\sum P(A_n) = \sum 1/n^2 = \pi^2/6 < +\infty$. Par le premier lemme de Borel-Cantelli, $P(A_n \text{ i.s.}) = 0$. Cela signifie qu'avec probabilité 1, il n'y aura qu'un nombre fini de Piles.
- Si la pièce est équilibrée, $P(A_n) = 1/2$ pour tout n . La série $\sum P(A_n) = \sum 1/2 = +\infty$. Les événements sont indépendants. Par le second lemme de Borel-Cantelli, $P(A_n \text{ i.s.}) = 1$. Cela signifie qu'avec probabilité 1, il y aura une infinité de Piles (et aussi une infinité de Faces, par le même raisonnement).

Exemple 1.50 (Paradoxe du Singe Savant (ou Dactylographe)). Un singe tape au hasard sur un clavier comportant L caractères (par ex. $L = 26$ lettres, plus espace, ponctuation). On suppose que chaque caractère est tapé indépendamment avec probabilité $1/L$. Soit une séquence spécifique de N caractères (par exemple, le titre "Hamlet"). Soit A_n l'événement que la séquence "Hamlet" (de longueur $N = 6$) commence à la n -ième position tapée par le singe. $P(A_n) = (1/L)^N$. La série $\sum P(A_n) = \sum (1/L)^N = +\infty$. Cependant, les événements A_n ne sont **pas** indépendants. Par exemple, si "HAMLET" est tapé commençant à la position n , alors il ne peut pas être tapé commençant à la position $n + 1$ (sauf si "AMLET" commence par H, ce qui n'est pas le cas). L'application directe du second lemme de Borel-Cantelli est délicate. Une version plus avancée (ou en considérant des blocs disjoints de frappes) montre que $P(A_n \text{ i.s.}) = 1$. Le singe finira (presque sûrement) par taper "Hamlet", et ce, une infinité de fois.

2 Variables Aléatoires

2.1 Variables aléatoires et leur loi

Définition 2.1 (Variable Aléatoire). Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. Une **variable aléatoire** (v.a.) réelle X est une application $X : \Omega \rightarrow \mathbb{R}$ telle que pour tout borélien $B \subseteq \mathbb{R}$ (un sous-ensemble "raisonnable" de $\mathbb{R}$, par exemple un intervalle), l'ensemble $\{\omega \in \Omega \mid X(\omega) \in B\}$ soit un événement, c'est-à-dire appartienne à la tribu $\mathcal{F}$.

$$X : \Omega \rightarrow \mathbb{R}$$

$$\omega \mapsto X(\omega)$$

La condition est que $X^{-1}(B) = \{\omega \in \Omega \mid X(\omega) \in B\} \in \mathcal{F}$ pour tout $B \in \mathcal{B}(\mathbb{R})$, où $\mathcal{B}(\mathbb{R})$ est la tribu borélienne sur $\mathbb{R}$ (la plus petite σ -algèbre contenant tous les intervalles ouverts de $\mathbb{R}$). On dit que X est $\mathcal{F}$ -mesurable.

Remarque 2.2. — Intuitivement, une variable aléatoire associe une valeur numérique à chaque issue possible d'une expérience aléatoire.

- La condition de mesurabilité assure que l'on peut calculer la probabilité d'événements de la forme $\{X \in B\}$, par exemple $P(X \leq x)$, $P(a < X \leq b)$, etc.
- On s'intéresse souvent à des événements du type $P(X \in U)$ (où U est un sous-ensemble de $\mathbb{R}$). On définit alors $P(X \in U) = P(\{\omega \in \Omega \mid X(\omega) \in U\}) = P(X^{-1}(U))$. Ceci est bien défini car $X^{-1}(U)$ est un événement (appartient à $\mathcal{F}$).

Exemple 2.3. Somme de 2 dés : $\Omega = \{(i, j) \mid i, j \in \{1, \dots, 6\}\}$. $\text{Card}(\Omega) = 36$. $\mathcal{F} = \mathcal{P}(\Omega)$. $P(\{\omega\}) = 1/36$ pour tout $\omega \in \Omega$. Soit X la variable aléatoire "somme des résultats des deux dés". $X : \Omega \rightarrow \mathbb{R}$. Par exemple, $X((1, 1)) = 2$, $X((1, 2)) = 3$, $X((6, 6)) = 12$. L'ensemble des valeurs possibles pour X est $\{2, 3, \dots, 12\}$. Calculons $P(X = 7)$. Les issues ω telles que $X(\omega) = 7$ sont : $(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)$. Il y en a 6. $X^{-1}(\{7\}) = \{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}$. $P(X = 7) = P(X^{-1}(\{7\})) = \text{Card}(X^{-1}(\{7\})) / \text{Card}(\Omega) = 6/36 = 1/6$.

Définition 2.4 (Loi de probabilité d'une variable aléatoire). La **loi de probabilité** de la variable aléatoire X , notée P_X , est la mesure de probabilité définie sur l'espace mesurable $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ par : Pour tout $B \in \mathcal{B}(\mathbb{R})$, $P_X(B) = P(X \in B) = P(X^{-1}(B))$. Connaître la loi de X signifie pouvoir calculer $P(X \in B)$ pour tout borélien B .

Définition 2.5 (Fonction de Répartition). La **fonction de répartition** (Cumulative Distribution Function, CDF) d'une variable aléatoire X est la fonction $F_X : \mathbb{R} \rightarrow [0, 1]$ définie par :

$$F_X(x) = P(X \leq x) \quad \text{pour tout } x \in \mathbb{R}$$

(C'est la probabilité que X prenne une valeur inférieure ou égale à x). Connaître la fonction de répartition F_X équivaut à connaître la loi de X , car F_X permet de retrouver $P_X(B)$ pour les boréliens B (notamment les intervalles).

Proposition 2.6 (Propriétés de la fonction de répartition). Une fonction $F : \mathbb{R} \rightarrow [0, 1]$ est une fonction de répartition si et seulement si elle satisfait les trois propriétés suivantes :

1. F est **croissante** (non décroissante) : si $x_1 \leq x_2$, alors $F(x_1) \leq F(x_2)$.
2. F est **continue à droite** (i.e., $\lim_{h \rightarrow 0^+} F(x+h) = F(x)$ pour tout $x \in \mathbb{R}$).
3. F a les limites suivantes aux infinis :

$$\lim_{x \rightarrow -\infty} F(x) = 0 \quad \text{et} \quad \lim_{x \rightarrow +\infty} F(x) = 1$$

Démonstration (esquisse des propriétés). 1. **Croissance** : Si $x_1 \leq x_2$, alors l'événement

$\{X \leq x_1\}$ est inclus dans l'événement $\{X \leq x_2\}$. Par monotonie de la mesure de probabilité P , $P(X \leq x_1) \leq P(X \leq x_2)$, donc $F_X(x_1) \leq F_X(x_2)$.

2. **Continuité à droite** : Soit $(h_n)_{n \in \mathbb{N}}$ une suite positive qui tend vers 0 (par exemple $h_n = 1/n$). Considérons les événements $A_n = \{X \leq x + h_n\}$. C'est une suite décroissante d'événements (si h_n est décroissante). Sa limite (intersection) est $\bigcap_{n=1}^{\infty} \{X \leq x + h_n\} = \{X \leq x\}$. Par continuité de la mesure de probabilité pour les suites monotones (Théorème 1.45) : $P(X \leq x) = P(\bigcap_{n=1}^{\infty} A_n) = \lim_{n \rightarrow \infty} P(A_n) = \lim_{n \rightarrow \infty} F_X(x + h_n)$. Ceci montre la continuité à droite.

3. **Limites aux infinis** :

- Pour $x \rightarrow -\infty$: Soit $x_n \rightarrow -\infty$ une suite décroissante. Les événements $A_n = \{X \leq x_n\}$ forment une suite décroissante dont l'intersection est $\bigcap_{n=1}^{\infty} A_n = \emptyset$ (car X prend des valeurs réelles). Donc $\lim_{x \rightarrow -\infty} F_X(x) = \lim_{n \rightarrow \infty} P(A_n) = P(\bigcap A_n) = P(\emptyset) = 0$.
- Pour $x \rightarrow +\infty$: Soit $x_n \rightarrow +\infty$ une suite croissante. Les événements $B_n = \{X \leq x_n\}$ forment une suite croissante dont l'union est $\bigcup_{n=1}^{\infty} B_n = \Omega$ (car X prend des valeurs réelles). Donc $\lim_{x \rightarrow +\infty} F_X(x) = \lim_{n \rightarrow \infty} P(B_n) = P(\bigcup B_n) = P(\Omega) = 1$.

□

Proposition 2.7 (Utilisation de la fonction de répartition). 1. $P(X > x) = 1 - P(X \leq x) = 1 - F_X(x)$.

2. $P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$ (pour $a < b$).
3. $P(X < x) = \lim_{h \rightarrow 0^+} P(X \leq x - h) = \lim_{h \rightarrow 0^+} F_X(x - h) = F_X(x^-)$ (limite à gauche de F_X en x).
4. $P(X = x) = P(X \leq x) - P(X < x) = F_X(x) - F_X(x^-)$. La probabilité $P(X = x)$ est non nulle si et seulement si F_X a un saut (une discontinuité) en x . La hauteur du saut est $P(X = x)$. Si F_X est continue en x , alors $P(X = x) = 0$.
5. $P(a \leq X \leq b) = P(X \leq b) - P(X < a) = F_X(b) - F_X(a^-)$.
6. $P(a < X < b) = P(X < b) - P(X \leq a) = F_X(b^-) - F_X(a)$.
7. $P(a \leq X < b) = P(X < b) - P(X < a) = F_X(b^-) - F_X(a^-)$.

Exemple 2.8 (Pile ou Face avec pièce truquée). Lancer d'une pièce. $X = 1$ si Pile (probabilité p), $X = 0$ si Face (probabilité $1 - p$). Fonction de répartition $F_X(x)$:

- Si $x < 0$, $P(X \leq x) = P(\emptyset) = 0$.

- Si $0 \leq x < 1$, $P(X \leq x) = P(X = 0) = 1 - p$.
- Si $x \geq 1$, $P(X \leq x) = P(X = 0 \text{ ou } X = 1) = P(X = 0) + P(X = 1) = (1 - p) + p = 1$.

Donc,

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - p & \text{si } 0 \leq x < 1 \\ 1 & \text{si } x \geq 1 \end{cases}$$

C'est une fonction en escalier, croissante, continue à droite. Elle a des sauts en $x = 0$ (hauteur $1 - p$) et en $x = 1$ (hauteur p). $P(X = 0) = F_X(0) - F_X(0^-) = (1 - p) - 0 = 1 - p$. $P(X = 1) = F_X(1) - F_X(1^-) = 1 - (1 - p) = p$.




FIGURE 8 – Fonction de répartition d'une v.a. de Bernoulli $X \sim \mathcal{B}(p)$

2.2 Variable Aléatoire Discrète

Définition 2.9 (Variable Aléatoire Discrète). Une variable aléatoire X est dite **discrète** si elle prend ses valeurs dans un ensemble fini ou dénombrable $\{x_1, x_2, \dots, x_k, \dots\}$. On suppose généralement les x_k ordonnés : $x_1 < x_2 < x_3 < \dots$. La loi d'une variable aléatoire discrète est entièrement caractérisée par sa **fonction de masse** (ou distribution de probabilité) qui donne les probabilités $P(X = x_k)$ pour chaque valeur x_k possible.

On note souvent $p_k = P(X = x_k)$. Ces probabilités doivent satisfaire :

- $p_k \geq 0$ pour tout k .
- $\sum_k p_k = 1$.

La fonction de répartition $F_X(x)$ d'une v.a. discrète est une fonction en escalier :

$$F_X(x) = P(X \leq x) = \sum_{x_k \leq x} P(X = x_k) = \sum_{x_k \leq x} p_k$$

Elle est constante par morceaux et saute aux points x_k où $P(X = x_k) > 0$. La hauteur du saut en x_k est $p_k = P(X = x_k)$.




FIGURE 9 – Fonction de répartition $F_X(x)$ d'une v.a. discrète et sauts $P(X = x_k)$

Connaître les $P(X = x_k)$ (la fonction de masse) $\iff$ Connaître $F_X(x)$.

- Si on connaît $P(X = x_k)$, on obtient $F_X(x) = \sum_{x_j \leq x} P(X = x_j)$.
- Si on connaît $F_X(x)$, on obtient $P(X = x_k) = F_X(x_k) - F_X(x_k^-)$. Si les x_k sont les points de discontinuité ordonnés $x_1 < x_2 < \dots$, alors $F_X(x_k^-) = F_X(x_{k-1})$ (en posant $F_X(x_0) = 0$ si x_1 est le premier point de discontinuité). Plus généralement, $F_X(x_k^-) = \lim_{y \uparrow x_k} F_X(y)$.

Remarque 2.10. La somme des probabilités $P(X = x_k)$ sur toutes les valeurs possibles x_k doit être égale à 1 : $\sum_k P(X = x_k) = 1$.




FIGURE 10 – Fonction de masse $P(X = x_k)$ d'une v.a. discrète (diagramme en bâtons)

Définition 2.11 (Espérance d'une v.a. discrète). L'espérance (ou valeur moyenne) d'une variable aléatoire discrète X prenant les valeurs x_k avec les probabilités $p_k = P(X = x_k)$ est définie par :

$$\mathbb{E}[X] = \sum_k x_k P(X = x_k) = \sum_k x_k p_k$$

à condition que la série $\sum_k |x_k| p_k$ converge (c'est-à-dire soit finie). Si la série diverge, on dit que l'espérance n'existe pas ou est infinie. L'espérance est un "indicateur de position" de la distribution.

Exemple 2.12 (Somme de 2 dés). X est la somme des résultats. Valeurs possibles $\{2, 3, \dots, 12\}$. Probabilités : $P(X = 2) = 1/36, P(X = 3) = 2/36, \dots, P(X = 7) = 6/36, \dots, P(X = 12) = 1/36$.

$$\begin{aligned} \mathbb{E}[X] &= 2 \cdot \frac{1}{36} + 3 \cdot \frac{2}{36} + 4 \cdot \frac{3}{36} + 5 \cdot \frac{4}{36} + 6 \cdot \frac{5}{36} + 7 \cdot \frac{6}{36} \\ &\quad + 8 \cdot \frac{5}{36} + 9 \cdot \frac{4}{36} + 10 \cdot \frac{3}{36} + 11 \cdot \frac{2}{36} + 12 \cdot \frac{1}{36} \\ &= \frac{1}{36} (2 + 6 + 12 + 20 + 30 + 42 + 40 + 36 + 30 + 22 + 12) \\ &= \frac{252}{36} = 7 \end{aligned}$$

Proposition 2.13 (Propriétés de l'espérance (cas discret)). 1. **Linéarité :** Pour $a, b \in \mathbb{R}$, $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$. Si X, Y sont deux v.a. discrètes définies sur le même Ω , $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ (si les espérances existent).

2. **Théorème de Transfert (LOTUS - Law Of The Unconscious Statistician) :** Soit X une v.a. discrète prenant les valeurs x_k avec probabilités p_k . Soit $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. Alors $Y = g(X)$ est une nouvelle variable aléatoire discrète. Son espérance est donnée par (si elle existe) :

$$\mathbb{E}[g(X)] = \sum_k g(x_k) P(X = x_k) = \sum_k g(x_k) p_k$$

Ceci est très utile car il n'est pas nécessaire de trouver la loi de $g(X)$ pour calculer son espérance.

Définition 2.14 (Variance d'une v.a. discrète). La **variance** d'une variable aléatoire discrète X (ayant une espérance $\mathbb{E}[X] = \mu$) est définie par :

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \sum_k (x_k - \mu)^2 P(X = x_k)$$

à condition que cette somme converge. La variance mesure la dispersion des valeurs de X autour de sa moyenne μ . Elle est toujours ≥ 0 . Une formule de calcul plus pratique (formule de Huygens) est :

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \mathbb{E}[X^2] - \mu^2$$

L'**écart-type** de X est $\sigma_X = \sqrt{\text{Var}(X)}$.

Proposition 2.15 (Propriétés de la variance). — $\text{Var}(X) \geq 0$.

- $\text{Var}(aX + b) = a^2 \text{Var}(X)$ pour $a, b \in \mathbb{R}$. (La translation b ne change pas la dispersion, le facteur a est élevé au carré).
- Si X et Y sont indépendantes, $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

Remarque 2.16 (L'espérance ne donne pas toute l'information). Deux variables aléatoires peuvent avoir la même espérance mais des variances très différentes. Exemple : Soit $X = 0$ (constante). $\mathbb{E}[X] = 0$, $\text{Var}(X) = 0$. Soit Y telle que $P(Y = 1000) = 1/2$ et $P(Y = -1000) = 1/2$. $\mathbb{E}[Y] = 0$. $\text{Var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2 = (1000^2 \cdot 1/2 + (-1000)^2 \cdot 1/2) - 0^2 = 1000^2 = 10^6$. La variance indique que Y est beaucoup plus "risquée" ou "dispersée" que X .

2.3 Variables Aléatoires Continues

Définition 2.17 (Variable aléatoire absolument continue). Soit X une variable aléatoire. X est dite **absolument continue** s'il existe une fonction $f_X : \mathbb{R} \rightarrow \mathbb{R}^+$, appelée **densité de probabilité** (ou fonction de densité), telle que pour tous réels $a \leq b$:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx$$

De plus, une densité de probabilité doit satisfaire deux conditions fondamentales :

1. **Positivité** : $f_X(x) \geq 0$ pour tout $x \in \mathbb{R}$. La densité ne peut pas être négative.
2. **Normalisation** : L'aire totale sous la courbe de la densité doit être égale à 1 :

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1$$

Remarque 2.18. Une conséquence importante est que pour une variable aléatoire continue X , la probabilité qu'elle prenne une valeur exacte x est nulle : $P(X = x) = \int_x^x f_X(t) dt = 0$ pour tout $x \in \mathbb{R}$. Cela implique que $P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b)$. Les inégalités strictes ou larges ne changent pas la probabilité pour les intervalles.

Définition 2.19 (Espérance et Variance d'une v.a. continue). Soit X une variable aléatoire absolument continue de densité f_X .

- L'**espérance** (ou valeur moyenne) de X est définie par (si l'intégrale converge absolument, c'est-à-dire si $\int_{-\infty}^{+\infty} |x|f_X(x) dx < \infty$) :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx$$

- **Théorème de transfert** (ou Loi de l'espérance inconsciente - LOTUS) : Pour une fonction $g : \mathbb{R} \rightarrow \mathbb{R}$ "raisonnable" (techniquement, une fonction borélienne), l'espérance de la variable aléatoire $Y = g(X)$ est donnée par (si l'intégrale converge absolument) :

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x) dx$$

Ce théorème est très utile car il évite de devoir trouver la densité de $g(X)$ pour calculer son espérance.

- La **variance** de X est définie par (si $\mathbb{E}[X^2]$ existe) :

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

La dernière égalité est la formule de Huygens pour la variance.

2.3.1 Interprétation de la densité

Pour un intervalle $[x, x+h]$ avec $h > 0$ "petit" (ou dx en notation infinitésimale) : $P(x \leq X \leq x+h) = \int_x^{x+h} f_X(t) dt$. Si f_X est continue en x , alors pour h petit, $\int_x^{x+h} f_X(t) dt \approx f_X(x) \cdot h$.¹ On peut donc voir $f_X(x)$ comme une "densité de probabilité" : $f_X(x) \approx \frac{P(x \leq X \leq x+h)}{h}$. Ce n'est pas une probabilité elle-même (elle peut être > 1), mais $f_X(x)dx$ est un élément de probabilité.

Lien avec la discrétisation (Approximation d'une v.a. continue par une v.a. discrète)

Soit $\tilde{X}$ une variable aléatoire discrète qui approxime X . On peut discrétiser l'axe réel en intervalles de longueur $h = 1/N$. Posons $x_k = k/N$. On peut définir $\tilde{X}$ telle que $\tilde{X} = x_k$ si $X \in [x_k, x_{k+1}[$ ($= [\frac{k}{N}, \frac{k+1}{N}[$). Pour N grand (donc h petit), on a $\tilde{X} \approx X$. L'espérance de X peut

1. Plus formellement, si $F_X(t) = \int_{-\infty}^t f_X(u) du$ est la fonction de répartition, et si f_X est continue en x , alors $P(x \leq X \leq x+h) = F_X(x+h) - F_X(x)$. Par le théorème des accroissements finis, il existe $c \in [x, x+h]$ tel que $F_X(x+h) - F_X(x) = F'_X(c) \cdot h = f_X(c) \cdot h$. Si f_X est continue, $f_X(c) \approx f_X(x)$ pour h petit. La relation plus exacte est $P(x \leq X \leq x+h) = f_X(x)h + o(h)$.

être approximée par l'espérance de $\tilde{X}$:

$$\begin{aligned}\mathbb{E}[X] &\approx \mathbb{E}[\tilde{X}] = \sum_{k=-\infty}^{+\infty} x_k P(\tilde{X} = x_k) \\ &= \sum_{k=-\infty}^{+\infty} \frac{k}{N} P\left(X \in \left[\frac{k}{N}, \frac{k+1}{N}\right]\right) \\ &\approx \sum_{k=-\infty}^{+\infty} \frac{k}{N} f_X\left(\frac{k}{N}\right) \frac{1}{N} \quad (\text{en posant } x_k = k/N \text{ et } h = 1/N) \\ &= \sum_{k=-\infty}^{+\infty} x_k f_X(x_k) h\end{aligned}$$

Cette dernière somme est une somme de Riemann. Lorsque $h \rightarrow 0$ (i.e., $N \rightarrow \infty$), elle converge vers l'intégrale $\int_{-\infty}^{+\infty} x f_X(x) dx$. Ceci fournit une intuition pour la formule de l'espérance d'une variable continue.

2.3.2 Quelques Variables Aléatoires Continues Usuelles

Distribution Uniforme

Une variable aléatoire continue X suit une **loi uniforme** sur l'intervalle $[a, b]$ (où $a < b$), notée $X \sim \mathcal{U}([a, b])$, si sa densité de probabilité f_X est constante sur $[a, b]$ et nulle ailleurs :

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in [a, b] \\ 0 & \text{sinon} \end{cases}$$

La constante $\frac{1}{b-a}$ assure que $\int_a^b f_X(x) dx = 1$. Sa fonction de répartition $F_X(x) = P(X \leq x)$ est :

$$F_X(x) = \int_{-\infty}^x f_X(t) dt = \begin{cases} 0 & \text{si } x < a \\ \int_a^x \frac{1}{b-a} dt = \frac{x-a}{b-a} & \text{si } a \leq x \leq b \\ 1 & \text{si } x > b \end{cases}$$

L'espérance et la variance sont : $\mathbb{E}[X] = \int_a^b x \frac{1}{b-a} dx = \frac{a+b}{2}$. $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{(b-a)^2}{12}$ (après calcul de $\mathbb{E}[X^2]$).




FIGURE 11 – Densité $f_X(x)$ de $\mathcal{U}([a, b])$




FIGURE 12 – Fonction de répartition $F_X(x)$ de $\mathcal{U}([a, b])$

Loi Exponentielle

Une variable aléatoire continue X suit une **loi exponentielle** de paramètre $\lambda > 0$ (appelé taux), notée $X \sim \mathcal{E}(\lambda)$ (ou $Exp(\lambda)$), si sa densité de probabilité est :

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{si } x < 0 \end{cases}$$

Sa fonction de répartition $F_X(x) = P(X \leq x)$ est, pour $x \geq 0$:

$$F_X(x) = \int_0^x \lambda e^{-\lambda t} dt = \lambda \left[-\frac{1}{\lambda} e^{-\lambda t} \right]_0^x = -e^{-\lambda x} - (-e^0) = 1 - e^{-\lambda x}$$

Donc,

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - e^{-\lambda x} & \text{si } x \geq 0 \end{cases}$$

On a $\mathbb{E}[X] = \frac{1}{\lambda}$ (durée de vie moyenne) et $\text{Var}(X) = \frac{1}{\lambda^2}$.

Proposition 2.20 (Propriété d'absence de mémoire). La loi exponentielle est la seule loi continue à support positif $[0, +\infty[$ qui possède la propriété d'absence de mémoire. Si $X \sim \mathcal{E}(\lambda)$, alors pour tous $s, t \geq 0$:

$$P(X > s + t \mid X > s) = P(X > t)$$

Cela signifie que si un appareil a déjà survécu un temps s , la probabilité qu'il survive un temps additionnel t est la même que la probabilité qu'un appareil neuf survive un temps t .




FIGURE 13 – Densité $f_X(x)$ de $\mathcal{E}(\lambda)$




FIGURE 14 – Fonction de répartition $F_X(x)$ de $\mathcal{E}(\lambda)$

Distribution d'Erlang (ou loi Gamma avec paramètre de forme entier)

Une variable aléatoire continue X suit une **loi d'Erlang** de paramètres $m \in \mathbb{N}^*$ (entier strictement positif, le nombre d'étapes ou la "forme") et $\lambda > 0$ (le "taux"), notée $X \sim \text{Erlang}(m, \lambda)$ (c'est un cas particulier de la loi Gamma $\Gamma(m, 1/\lambda)$ ou $\Gamma(m, \lambda)$ selon la paramétrisation de la loi Gamma, ici avec λ comme paramètre de taux), si sa densité de probabilité f_X est :

$$f_X(x) = \begin{cases} \frac{\lambda^m x^{m-1} e^{-\lambda x}}{(m-1)!} & \text{si } x \geq 0 \\ 0 & \text{si } x < 0 \end{cases}$$

Remarque 2.21. — Si $m = 1$, on retrouve la loi exponentielle $\mathcal{E}(\lambda)$: $f_X(x) = \frac{\lambda^1 x^{1-1} e^{-\lambda x}}{0!} = \lambda e^{-\lambda x}$ pour $x \geq 0$.

- La loi d'Erlang $X \sim \text{Erlang}(m, \lambda)$ peut être vue comme la somme de m variables aléatoires indépendantes et identiquement distribuées (i.i.d.) suivant chacune une loi exponentielle $\mathcal{E}(\lambda)$. Si $Y_1, Y_2, \dots, Y_m$ sont i.i.d. $\mathcal{E}(\lambda)$, alors $X = \sum_{i=1}^m Y_i \sim \text{Erlang}(m, \lambda)$. Cette interprétation est utile pour les processus de Poisson (temps d'attente du m -ième événement).

Puisque $X = \sum_{i=1}^m Y_i$ avec $Y_i \sim \mathcal{E}(\lambda)$ i.i.d. : $\mathbb{E}[X] = \mathbb{E}[\sum Y_i] = \sum \mathbb{E}[Y_i] = \sum_{i=1}^m \frac{1}{\lambda} = \frac{m}{\lambda}$.
 $\text{Var}(X) = \text{Var}(\sum Y_i) = \sum \text{Var}(Y_i)$ (par indépendance) $= \sum_{i=1}^m \frac{1}{\lambda^2} = \frac{m}{\lambda^2}$.




FIGURE 15 – Densité $f_X(x)$ de $\text{Erlang}(m, \lambda)$ pour $m = 2, \lambda = 1$

Loi Normale (ou Gaussienne)

Une variable aléatoire continue X suit une **loi normale** (ou **gaussienne**) de paramètres $\mu \in \mathbb{R}$ (la moyenne) et $\sigma^2 > 0$ (la variance, avec $\sigma = \sqrt{\sigma^2} > 0$ l'écart-type), notée $X \sim \mathcal{N}(\mu, \sigma^2)$, si sa densité de probabilité f_X est donnée par :

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad \text{pour tout } x \in \mathbb{R}$$

On peut vérifier (bien que le calcul soit non trivial, impliquant souvent une astuce avec les intégrales doubles ou l'intégration dans le plan complexe) que cette fonction est bien une densité de probabilité, notamment que $\int_{-\infty}^{+\infty} f_X(x) dx = 1$. La fonction de répartition $F_X(x) = P(X \leq x)$ n'admet pas d'expression simple à l'aide des fonctions usuelles (on dit qu'elle n'a pas de forme analytique close). On la calcule numériquement. Par définition des paramètres de cette loi, on a :

- Espérance : $\mathbb{E}[X] = \mu$
- Variance : $\text{Var}(X) = \sigma^2$

Remarque 2.22 (Loi Normale Centrée Réduite). Un cas particulier très important est la **loi normale centrée réduite**, obtenue pour $\mu = 0$ et $\sigma^2 = 1$. Une variable Z suivant cette loi est notée $Z \sim \mathcal{N}(0, 1)$. Sa densité est souvent notée $\phi(z)$:

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$$

Sa fonction de répartition est souvent notée $\Phi(z) = \int_{-\infty}^z \phi(t) dt$. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors la variable $Z = \frac{X-\mu}{\sigma}$ suit une loi $\mathcal{N}(0, 1)$. Cette transformation est appelée **standardisation** ou **centrage-réduction**.

Le calcul de $\mathbb{E}[X] = \mu$ (pour $\mathcal{N}(\mu, \sigma^2)$) se fait par le changement de variable $y = (x - \mu)/\sigma$. On obtient : $\mathbb{E}[X] = \int_{-\infty}^{+\infty} (\sigma y + \mu) \phi(y) dy = \sigma \int_{-\infty}^{+\infty} y \phi(y) dy + \mu \int_{-\infty}^{+\infty} \phi(y) dy$. La première intégrale $\int y \phi(y) dy = \mathbb{E}[Z] = 0$ car $y \phi(y)$ est une fonction impaire intégrée sur un intervalle symétrique. La seconde intégrale $\int \phi(y) dy = 1$ car ϕ est une densité. Donc $\mathbb{E}[X] = \sigma \cdot 0 + \mu \cdot 1 = \mu$.

Le calcul de $\text{Var}(X) = \sigma^2$ utilise $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$. $\mathbb{E}[X^2] = \int_{-\infty}^{+\infty} (\sigma y + \mu)^2 \phi(y) dy = \sigma^2 \int y^2 \phi(y) dy + 2\sigma\mu \int y \phi(y) dy + \mu^2 \int \phi(y) dy$. On a $\int y^2 \phi(y) dy = \mathbb{E}[Z^2]$. Pour $Z \sim \mathcal{N}(0, 1)$, $\text{Var}(Z) = \mathbb{E}[Z^2] - (\mathbb{E}[Z])^2 = \mathbb{E}[Z^2] - 0^2 = \mathbb{E}[Z^2]$. Comme $\text{Var}(Z) = 1$, on a $\mathbb{E}[Z^2] = 1$. Donc $\mathbb{E}[X^2] = \sigma^2 \cdot 1 + 2\sigma\mu \cdot 0 + \mu^2 \cdot 1 = \sigma^2 + \mu^2$. Finalement, $\text{Var}(X) = (\sigma^2 + \mu^2) - \mu^2 = \sigma^2$.




FIGURE 16 – Fonction de répartition d'une loi Normale $\mathcal{N}(0, 1)$ (approximation).

Proposition 2.23 (Transformation affine d'une v.a. normale). Si $X \sim \mathcal{N}(\mu, \sigma^2)$ et $a, b \in \mathbb{R}$ avec $a \neq 0$. Alors $Y = aX + b \sim \mathcal{N}(a\mu + b, (a\sigma)^2)$.

Démonstration. (Esquisse) On utilise la méthode de la fonction de répartition. $F_Y(y) = P(Y \leq y) = P(aX + b \leq y)$. Si $a > 0$, $P(X \leq \frac{y-b}{a}) = F_X\left(\frac{y-b}{a}\right)$. Alors $f_Y(y) = \frac{d}{dy} F_Y(y) = f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{a}$. En substituant l'expression de f_X et en réarrangeant les termes, on obtient la densité d'une loi $\mathcal{N}(a\mu + b, (a\sigma)^2)$. Si $a < 0$, $P(aX + b \leq y) = P(X \geq \frac{y-b}{a}) = 1 - F_X\left(\frac{y-b}{a}\right)$. Alors $f_Y(y) = -f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{a} = f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{|a|}$. Le résultat final est le même car $(a\sigma)^2 = (|a|\sigma)^2$. $\square$

Proposition 2.24 (Somme de v.a. normales indépendantes). Si $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$, et si $X \perp\!\!\!\perp Y$. Alors $Z = X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. (Ceci se démontre élégamment avec les fonctions caractéristiques, voir Section 5.4).

2.4 Remarque : Variable aléatoire générale

Il existe des variables aléatoires qui ne sont ni purement discrètes (ne prenant qu'un nombre fini ou dénombrable de valeurs avec des masses de probabilité) ni purement (absolument) continues (possédant une densité de probabilité). Elles peuvent être une combinaison des deux, on parle alors de **variables mixtes**. Leur fonction de répartition est alors une combinaison de sauts (pour les parties discrètes) et de portions continues (pour les parties continues).

Exemple 2.25 (Variable mixte). Soit $X \sim \mathcal{E}(\lambda)$ une variable aléatoire exponentielle (continue). Considérons $Y = \min(X, 1)$. La variable Y est bornée par 1.

- Si $X \geq 1$, alors $Y = 1$. La probabilité de cet événement est $P(Y = 1) = P(X \geq 1) = \int_1^\infty \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_1^\infty = 0 - (-e^{-\lambda}) = e^{-\lambda}$. Il y a donc une **masse de probabilité** (une probabilité ponctuelle non nulle) en $Y = 1$.
- Si $0 \leq X < 1$, alors $Y = X$. Pour $0 \leq y < 1$, l'événement $\{Y \leq y\}$ est équivalent à $\{X \leq y\}$. Donc $F_Y(y) = P(Y \leq y) = P(X \leq y) = 1 - e^{-\lambda y}$ pour $0 \leq y < 1$. Sur l'intervalle $[0, 1[$, Y se comporte comme une variable continue, et on pourrait définir une "densité" $f_Y(y) = \frac{d}{dy}(1 - e^{-\lambda y}) = \lambda e^{-\lambda y}$ pour $0 \leq y < 1$.

La fonction de répartition complète de Y est :

$$F_Y(y) = \begin{cases} 0 & \text{si } y < 0 \\ 1 - e^{-\lambda y} & \text{si } 0 \leq y < 1 \\ 1 & \text{si } y \geq 1 \end{cases}$$

On observe un saut en $y = 1$ de taille $P(Y = 1) = e^{-\lambda}$, car $F_Y(1) - \lim_{y \rightarrow 1^-} F_Y(y) = 1 - (1 - e^{-\lambda}) = e^{-\lambda}$.




FIGURE 17 – Fonction de répartition $F_Y(y)$ de $Y = \min(X, 1)$ où $X \sim \mathcal{E}(\lambda)$

2.5 Propriétés de l'espérance (cas général)

Soient X, Y des variables aléatoires définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$, et $\alpha \in \mathbb{R}$.

1. **Linéarité de l'espérance** : Si $\mathbb{E}[X]$ et $\mathbb{E}[Y]$ existent, alors $\mathbb{E}[\alpha X + Y]$ existe et $\mathbb{E}[\alpha X + Y] = \alpha \mathbb{E}[X] + \mathbb{E}[Y]$.
2. **Monotonie de l'espérance** : Si $X \leq Y$ presque sûrement (p.s.) (c'est-à-dire $P(X \leq Y) = 1$), et si $\mathbb{E}[X]$ et $\mathbb{E}[Y]$ existent, alors $\mathbb{E}[X] \leq \mathbb{E}[Y]$.
3. **Moments** : Si $\mathbb{E}[|X|^k] < +\infty$ pour un certain $k \geq 1$ (on dit que X admet un moment d'ordre k), alors $\mathbb{E}[|X|^j] < +\infty$ pour tout $1 \leq j \leq k$ (X admet tous les moments d'ordre inférieur).

3 Distributions Jointes, Indépendance

Soient X et Y deux variables aléatoires définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$. On s'intéresse souvent au comportement simultané de ces variables, ce qui nous amène à considérer le **vecteur aléatoire** (X, Y) .

3.1 Fonction de répartition jointe

La **fonction de répartition jointe** du couple (X, Y) est la fonction $F_{X,Y} : \mathbb{R}^2 \rightarrow [0, 1]$ définie par :

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y) \quad \text{pour tous } (x, y) \in \mathbb{R}^2$$

(Rappel : la virgule dans $P(A, B)$ signifie $P(A \cap B)$, c'est-à-dire $P(A \text{ et } B)$). Connaître la fonction de répartition jointe $F_{X,Y}(x, y)$ équivaut à connaître la loi de probabilité du couple (X, Y) .

En particulier, on peut retrouver la probabilité que (X, Y) appartienne à un "rectangle" de la forme $]a, b] \times]c, d]$: Pour $a < b$ et $c < d$,

$$\begin{aligned} P(a < X \leq b, c < Y \leq d) &= P(X \leq b, Y \leq d) - P(X \leq a, Y \leq d) \\ &\quad - P(X \leq b, Y \leq c) + P(X \leq a, Y \leq c) \\ &= F_{X,Y}(b, d) - F_{X,Y}(a, d) - F_{X,Y}(b, c) + F_{X,Y}(a, c) \end{aligned}$$

Ceci est une conséquence du principe d'inclusion-exclusion.




FIGURE 18 – Probabilité d'un rectangle $]a, b] \times]c, d]$ via la fonction de répartition jointe

3.2 Cas où (X, Y) est un couple de variables aléatoires discrètes

Si (X, Y) est un couple de variables aléatoires discrètes, c'est-à-dire que X prend des valeurs dans un ensemble fini ou dénombrable $\{x_i\}_{i \in I}$ et Y prend des valeurs dans $\{y_j\}_{j \in J}$, alors la loi du couple est entièrement déterminée par la **fonction de masse conjointe** (ou loi de probabilité conjointe) :

$$p_{ij} = P(X = x_i, Y = y_j)$$

Cette fonction doit satisfaire $p_{ij} \geq 0$ pour tous i, j et $\sum_{i \in I} \sum_{j \in J} p_{ij} = 1$. La fonction de répartition jointe $F_{X,Y}(x, y)$ est alors obtenue par sommation : $F_{X,Y}(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{ij}$.

Exemple 3.1 (Suite de l'exemple des lancers de pièce). On lance 2 fois une pièce équilibrée. $X \sim \text{Bernoulli}(1/2)$ est le résultat du 1er lancer (1 si Pile, 0 si Face), $Y \sim \text{Bernoulli}(1/2)$ est le résultat du 2e lancer.

Cas 1 (X, Y indépendantes et identiquement distribuées (i.i.d.)) : $P(X = x, Y = y) = P(X = x)P(Y = y)$ pour $x, y \in \{0, 1\}$. $p_{00} = P(X = 0, Y = 0) = (1/2)(1/2) = 1/4$. De même, $p_{01} = P(X = 0, Y = 1) = 1/4$, $p_{10} = P(X = 1, Y = 0) = 1/4$, $p_{11} = P(X = 1, Y = 1) = 1/4$. La loi conjointe peut être représentée dans un tableau :

$X \setminus Y$	0 (Face)	1 (Pile)	$P(X = x)$ (Marginale de X)
0 (Face)	1/4	1/4	1/2
1 (Pile)	1/4	1/4	1/2
$P(Y = y)$ (Marginale de Y)	1/2	1/2	1 (Total)

Cas 2 ($X \sim \text{Bernoulli}(1/2)$, Y dépend de X) : Supposons que la loi de Y dépende du résultat de X de la manière suivante : $P(Y = 1|X = 0) = 1/3$ (donc $P(Y = 0|X = 0) = 2/3$) $P(Y = 1|X = 1) = 2/3$ (donc $P(Y = 0|X = 1) = 1/3$) On calcule les probabilités jointes : $P(X = 0, Y = 0) = P(Y = 0|X = 0)P(X = 0) = (2/3) \cdot (1/2) = 1/3$. $P(X = 0, Y = 1) = P(Y = 1|X = 0)P(X = 0) = (1/3) \cdot (1/2) = 1/6$. $P(X = 1, Y = 0) = P(Y = 0|X = 1)P(X = 1) = (1/3) \cdot (1/2) = 1/6$. $P(X = 1, Y = 1) = P(Y = 1|X = 1)P(X = 1) = (2/3) \cdot (1/2) = 1/3$. Tableau de la loi conjointe :

$X \setminus Y$	0	1	$P(X = x)$
0	1/3	1/6	1/2
1	1/6	1/3	1/2
$P(Y = y)$	1/2	1/2	1 (Total)

(La somme des probabilités $1/3 + 1/6 + 1/6 + 1/3 = 2/6 + 1/6 + 1/6 + 2/6 = 6/6 = 1$).

Exemple 3.2 (Urne avec 3 Boules Bleues, 5 Rouges, 2 Noires. Tirage simultané (ou sans remise) de 2 boules). Soit X le nombre de boules Bleues tirées ($X \in \{0, 1, 2\}$). Soit Y le nombre de boules Rouges tirées ($Y \in \{0, 1, 2\}$). Le nombre total de façons de tirer 2 boules parmi 10 est $\binom{10}{2} = \frac{10 \times 9}{2} = 45$. La fonction de masse conjointe $P(X = x, Y = y)$ est donnée par :

$$P(X = x, Y = y) = \frac{\binom{3}{x} \binom{5}{y} \binom{2}{2-x-y}}{\binom{10}{2}}$$

pour $x, y \geq 0$ et $x + y \leq 2$. Calculs : $P(X = 0, Y = 0) = \frac{\binom{3}{0} \binom{5}{0} \binom{2}{2}}{45} = 1/45$, $P(X = 0, Y = 1) = \frac{\binom{3}{0} \binom{5}{1} \binom{2}{1}}{45} = 10/45$, $P(X = 0, Y = 2) = \frac{\binom{3}{0} \binom{5}{2} \binom{2}{0}}{45} = 10/45$, $P(X = 1, Y = 0) = \frac{\binom{3}{1} \binom{5}{0} \binom{2}{1}}{45} = 6/45$, $P(X = 1, Y = 1) = \frac{\binom{3}{1} \binom{5}{1} \binom{2}{0}}{45} = 15/45$, $P(X = 2, Y = 0) = \frac{\binom{3}{2} \binom{5}{0} \binom{2}{0}}{45} = 3/45$. Toutes les autres paires (x, y) ont une probabilité nulle.

$X \setminus Y$	0	1	2	$P(X = x)$ (Marginale X)
0	1/45	10/45	10/45	21/45
1	6/45	15/45	0	21/45
2	3/45	0	0	3/45
$P(Y = y)$ (Marginale Y)	10/45	25/45	10/45	1 (Total = 45/45)

3.3 Cas où (X, Y) est un couple de variables aléatoires (absolument) continues

Le couple (X, Y) est dit conjointement (absolument) continu s'il existe une fonction $f_{X,Y} : \mathbb{R}^2 \rightarrow \mathbb{R}^+$, appelée **densité de probabilité jointe**, telle que pour tous $(x, y) \in \mathbb{R}^2$:

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) dv du$$

Cela implique que pour un domaine $A \subset \mathbb{R}^2$ (par exemple un borélien de $\mathbb{R}^2$) :

$$P((X, Y) \in A) = \iint_A f_{X,Y}(u, v) du dv$$

Propriétés de la densité jointe :

- $f_{X,Y}(x, y) \geq 0$ pour tous $(x, y) \in \mathbb{R}^2$.
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy dx = 1$.
- Si $F_{X,Y}$ est suffisamment régulière (par exemple, si ses dérivées partielles croisées existent et sont continues), alors $f_{X,Y}(x, y) = \frac{\partial^2 F_{X,Y}(x, y)}{\partial x \partial y}$.

Exemple 3.3 (Loi uniforme sur un domaine D). Lancer d'une fléchette sur une cible circulaire $D = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 \leq R^2\}$ de rayon R . On suppose que la fléchette atteint toujours la cible et que la probabilité d'atteindre une région est proportionnelle à l'aire de cette région. La densité jointe du point d'impact (X, Y) est :

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{\text{Aire}(D)} & \text{si } (x, y) \in D \\ 0 & \text{sinon} \end{cases}$$

Comme $\text{Aire}(D) = \pi R^2$, on a $f_{X,Y}(x, y) = \frac{1}{\pi R^2}$ si $(x, y) \in D$, et 0 sinon. Pour un sous-ensemble $A \subseteq D$, $P((X, Y) \in A) = \iint_A \frac{1}{\pi R^2} dx dy = \frac{\text{Aire}(A)}{\text{Aire}(D)}$.

3.4 Lois Marginales

La **loi marginale** de X est la loi de la variable aléatoire X considérée seule, sans tenir compte de Y . De même pour Y . On peut obtenir les fonctions de répartition marginales à partir de la fonction de répartition jointe : $F_X(x) = P(X \leq x) = P(X \leq x, Y < +\infty) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y)$. (Parfois noté $F_{X,Y}(x, \infty)$). $F_Y(y) = P(Y \leq y) = P(X < +\infty, Y \leq y) = \lim_{x \rightarrow +\infty} F_{X,Y}(x, y)$. (Parfois noté $F_{X,Y}(\infty, y)$).

Cas discret : Les probabilités (fonctions de masse) marginales s'obtiennent en sommant la loi jointe sur toutes les valeurs possibles de l'autre variable : $P(X = x_i) = \sum_{j \in J} P(X = x_i, Y = y_j) = \sum_{j \in J} p_{ij}$. (Somme sur la ligne i du tableau de probabilités conjointes). $P(Y = y_j) = \sum_{i \in I} P(X = x_i, Y = y_j) = \sum_{i \in I} p_{ij}$. (Somme sur la colonne j du tableau).

Cas continu : Les densités marginales s'obtiennent en intégrant la densité jointe par rapport à l'autre variable sur tout son domaine : $f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy$. $f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx$.

Densité jointe $f_{X,Y}(x, y)$ et marginales




FIGURE 19 – Densité jointe $\mathcal{N}((0, 0), I_2)$ et marginales $\mathcal{N}(0, 1)$ (marginales visuellement mises à l'échelle).

3.5 Indépendance de Variables Aléatoires

Définition 3.4 (Indépendance de deux variables aléatoires). Soient X et Y deux variables aléatoires définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$. X et Y sont dites **indépendantes** (noté $X \perp\!\!\!\perp Y$ ou parfois $X \perp Y$) si pour tous ensembles boréliens $A, B \subset \mathbb{R}$ (c'est-à-dire des sous-ensembles "raisonnables" de $\mathbb{R}$ pour lesquels $P(X \in A)$ et $P(Y \in B)$ sont bien définis) :

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

Cela signifie que les événements $\{X \in A\}$ et $\{Y \in B\}$ sont indépendants pour tous choix de A et B .

Proposition 3.5 (Caractérisation de l'indépendance). L'indépendance de X et Y peut être caractérisée de plusieurs manières équivalentes :

- Par la fonction de répartition jointe : $X \perp\!\!\!\perp Y \iff F_{X,Y}(x, y) = F_X(x)F_Y(y)$ pour tous $(x, y) \in \mathbb{R}^2$.
- Cas discret : $X \perp\!\!\!\perp Y \iff P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$ pour toutes les valeurs x_i, y_j prises par X et Y . (Autrement dit, $p_{ij} = p_{i.} \times p_{.j}$, où $p_{i.}$ et $p_{.j}$ sont les probabilités marginales).
- Cas continu : Si X et Y admettent des densités marginales f_X et f_Y , elles sont indépendantes si et seulement si le couple (X, Y) admet pour densité jointe le produit des densités marginales : $f_{X,Y}(x, y) = f_X(x)f_Y(y)$ pour (presque) tous $(x, y) \in \mathbb{R}^2$.

Proposition 3.6 (Espérance du produit de v.a. indépendantes). Si X et Y sont deux variables aléatoires indépendantes :

1. Pour toutes fonctions (mesurables) $g : \mathbb{R} \rightarrow \mathbb{R}$ et $h : \mathbb{R} \rightarrow \mathbb{R}$, les variables aléatoires $g(X)$ et $h(Y)$ sont également indépendantes.

2. Si $\mathbb{E}[X]$ et $\mathbb{E}[Y]$ existent (et sont finies), et si $\mathbb{E}[XY]$ existe (ce qui est garanti si X, Y sont bornées, par exemple, ou par des conditions de moments plus faibles), alors :

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$$

Plus généralement, si $g(X)$ et $h(Y)$ ont des espérances finies :

$$\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$$

Proposition 3.7 (Variance de la somme de v.a. indépendantes). Si X et Y sont deux variables aléatoires indépendantes et si leurs variances $\text{Var}(X)$ et $\text{Var}(Y)$ existent (sont finies) :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

Démonstration. On sait que, de manière générale, $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$. Si $X \perp\!\!\!\perp Y$, alors $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$. Puisque $X - \mathbb{E}[X]$ est une fonction de X , et $Y - \mathbb{E}[Y]$ est une fonction de Y , et que $X \perp\!\!\!\perp Y$, les variables $X - \mathbb{E}[X]$ et $Y - \mathbb{E}[Y]$ sont aussi indépendantes. Donc, par la propriété de l'espérance du produit de variables indépendantes (Point 2 de :esperance_produit_indep@cref

:esperance_produit_indep@cref

:esperance_produit_indep@cref

:esperance_produit_indep@cref

?? appliqué à $g(X) = X - \mathbb{E}[X]$ et $h(Y) = Y - \mathbb{E}[Y]$: $\text{Cov}(X, Y) = \mathbb{E}[X - \mathbb{E}[X]] \cdot \mathbb{E}[Y - \mathbb{E}[Y]]$. Or, $\mathbb{E}[X - \mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[\mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[X] = 0$. De même, $\mathbb{E}[Y - \mathbb{E}[Y]] = 0$. Ainsi, $\text{Cov}(X, Y) = 0 \cdot 0 = 0$. D'où $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ si $X \perp\!\!\!\perp Y$. $\square$

3.6 Covariance entre deux Variables Aléatoires

Soit (X, Y) un couple de variables aléatoires telles que $\mathbb{E}[X^2] < \infty$ et $\mathbb{E}[Y^2] < \infty$ (ceci garantit que $\mathbb{E}[X]$, $\mathbb{E}[Y]$, $\text{Var}(X)$, $\text{Var}(Y)$ existent et sont finies, et par Cauchy-Schwarz, que $\mathbb{E}[|XY|]$ existe aussi).

Définition 3.8 (Covariance). La **covariance** de X et Y est définie par :

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Elle mesure la tendance des variables à varier ensemble par rapport à leurs moyennes. Une formule de calcul plus pratique est la formule de Huygens pour la covariance :

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Interprétation de la covariance :

- Si $\text{Cov}(X, Y) > 0$: X et Y ont tendance à varier dans le même sens. Quand X est au-dessus de sa moyenne, Y a tendance à l'être aussi, et vice-versa.

- Si $\text{Cov}(X, Y) < 0$: X et Y ont tendance à varier en sens opposés. Quand X est au-dessus de sa moyenne, Y a tendance à être en dessous, et vice-versa.
- Si $\text{Cov}(X, Y) = 0$: On dit que X et Y sont **non corrélées**. Cela indique une absence de relation *linéaire* entre X et Y .




FIGURE 20 – Interprétation graphique de la covariance

Proposition 3.9. Si X et Y sont indépendantes (et que leurs espérances existent), alors $\text{Cov}(X, Y) = 0$.

Démonstration. Si $X \perp\!\!\!\perp Y$, alors $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. Donc $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y] = 0$. $\square$

Remarque 3.10 (Attention à la réciproque). La réciproque est **fausse** en général : $\text{Cov}(X, Y) = 0$ (variables non corrélées) n'implique **pas** que X et Y sont indépendantes. L'indépendance est une condition plus forte que la non-corrélation. Contre-exemple : Soit X une variable aléatoire telle que $\mathbb{E}[X] = 0$ et $\mathbb{E}[X^3] = 0$ (par exemple $X \sim \mathcal{N}(0, 1)$ ou X une variable uniforme sur $[-c, c]$). Soit $Y = X^2$. Alors X et Y sont clairement dépendantes (connaître X détermine Y). $\mathbb{E}[Y] = \mathbb{E}[X^2]$. $\mathbb{E}[XY] = \mathbb{E}[X \cdot X^2] = \mathbb{E}[X^3] = 0$ (par hypothèse sur X). $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0 - 0 \cdot \mathbb{E}[X^2] = 0$.

4 Vecteurs Aléatoires

Un **vecteur aléatoire** X de dimension m est un vecteur $X = (X_1, X_2, \dots, X_m)^T$ (souvent représenté comme un vecteur colonne) où chaque composante X_i est une variable aléatoire réelle définie sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$. On a déjà étudié le cas $m = 2$ avec le couple (X, Y) . La plupart des concepts se généralisent.

4.1 Fonction de répartition d'un vecteur aléatoire

La fonction de répartition (jointe) du vecteur aléatoire $X = (X_1, \dots, X_m)$ est la fonction $F_X : \mathbb{R}^m \rightarrow [0, 1]$ définie par :

$$F_X(x_1, \dots, x_m) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_m \leq x_m)$$

pour tous $(x_1, \dots, x_m) \in \mathbb{R}^m$.




FIGURE 21 – Illustration de la fonction de répartition jointe $F_{X_1, X_2}(x_1, x_2)$ pour $m = 2$

4.2 Indépendance mutuelle des composantes

Les variables aléatoires $X_1, \dots, X_m$ sont dites **mutuellement indépendantes** si, pour tous choix d'ensembles boréliens $A_1, \dots, A_m \subset \mathbb{R}$:

$$P(X_1 \in A_1, X_2 \in A_2, \dots, X_m \in A_m) = P(X_1 \in A_1)P(X_2 \in A_2) \dots P(X_m \in A_m)$$

Cela est équivalent à dire que la fonction de répartition jointe est le produit des fonctions de répartition marginales :

$$F_X(x_1, \dots, x_m) = F_{X_1}(x_1)F_{X_2}(x_2) \dots F_{X_m}(x_m) \quad \text{pour tous } (x_1, \dots, x_m)$$

Si les X_i admettent des densités marginales f_{X_i} , alors l'indépendance mutuelle est équivalente à ce que la densité jointe du vecteur X soit le produit des densités marginales : $f_X(x_1, \dots, x_m) = f_{X_1}(x_1)f_{X_2}(x_2) \dots f_{X_m}(x_m)$ (presque partout).

4.3 Espérance d'un vecteur aléatoire

L'espérance du vecteur aléatoire $X = (X_1, \dots, X_m)^T$ est le vecteur (colonne) des espérances de ses composantes (si elles existent) :

$$\mathbb{E}[X] = \begin{pmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_m] \end{pmatrix} = (\mathbb{E}[X_1], \mathbb{E}[X_2], \dots, \mathbb{E}[X_m])^T$$

4.4 Matrice de Covariance

La **matrice de covariance** du vecteur aléatoire $X = (X_1, \dots, X_m)^T$ est une matrice carrée de taille $m \times m$, notée $\text{Cov}(X)$ ou Σ , dont l'élément (i, j) est $\Sigma_{ij} = \text{Cov}(X_i, X_j)$.

$$\Sigma = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_m) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \dots & \text{Cov}(X_2, X_m) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_m, X_1) & \text{Cov}(X_m, X_2) & \dots & \text{Var}(X_m) \end{pmatrix}$$

Notez que $\text{Cov}(X_i, X_i) = \text{Var}(X_i)$. La matrice de covariance peut aussi s'écrire de manière compacte en utilisant les vecteurs d'espérance $\boldsymbol{\mu} = \mathbb{E}[X]$:

$$\Sigma = \mathbb{E}[(X - \boldsymbol{\mu})(X - \boldsymbol{\mu})^T]$$

où $(X - \boldsymbol{\mu})$ est un vecteur colonne et $(X - \boldsymbol{\mu})^T$ est son transposé (vecteur ligne), leur produit est donc une matrice $m \times m$. Propriétés de la matrice de covariance :

- Σ est **symétrique** : $\Sigma_{ij} = \text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i) = \Sigma_{ji}$.
- Σ est **semi-définie positive** : pour tout vecteur constant non nul $\mathbf{a} \in \mathbb{R}^m$, $\mathbf{a}^T \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^T X) \geq 0$.
- Si les composantes X_i sont **mutuellement indépendantes** (ou simplement non corrélées deux à deux), alors $\text{Cov}(X_i, X_j) = 0$ pour $i \neq j$. Dans ce cas, Σ est une **matrice diagonale** avec les variances $\text{Var}(X_i)$ sur la diagonale.

4.5 Distribution Multinomiale

La loi multinomiale est une généralisation de la loi binomiale à des expériences ayant plus de deux issues possibles.

Définition 4.1 (Loi Multinomiale). Considérons une expérience aléatoire qui peut avoir k issues (ou catégories) possibles, mutuellement exclusives, $R_1, R_2, \dots, R_k$. Supposons que la probabilité de l'issue R_j est p_j , avec $p_j \geq 0$ pour tout $j = 1, \dots, k$ et $\sum_{j=1}^k p_j = 1$. On répète cette expérience n fois de manière indépendante. Soit X_j le nombre de fois que l'issue R_j est observée au cours des n répétitions. Le vecteur aléatoire $X = (X_1, X_2, \dots, X_k)$ suit une **loi multinomiale** de paramètres n (nombre d'essais) et $(p_1, p_2, \dots, p_k)$ (probabilités des issues), notée $X \sim \mathcal{M}(n; p_1, \dots, p_k)$.

$$\begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \text{Cov}(X_1, X_3) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \text{Cov}(X_2, X_3) \\ \text{Cov}(X_3, X_1) & \text{Cov}(X_3, X_2) & \text{Var}(X_3) \end{pmatrix}$$

Structure de la matrice de covariance Σ pour $m = 3$.
 Les termes sur la diagonale (bleu) sont les variances.
 Les termes hors diagonale (vert) sont les covariances.
 La matrice est symétrique ($\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$), indiqué par les pointillés pour les termes en dessous de la diagonale).

FIGURE 22 – Illustration de la Matrice de Covariance Σ pour un vecteur aléatoire $(X_1, X_2, X_3)^T$.

Notez que les X_j ne sont pas indépendantes car leur somme est fixée : $\sum_{j=1}^k X_j = n$. La fonction de masse conjointe du vecteur X est :

$$P(X_1 = n_1, X_2 = n_2, \dots, X_k = n_k) = \frac{n!}{n_1! n_2! \dots n_k!} p_1^{n_1} p_2^{n_2} \dots p_k^{n_k}$$

pour tous entiers $n_j \geq 0$ tels que $\sum_{j=1}^k n_j = n$. Si cette condition n'est pas remplie, la probabilité est nulle. Le terme $\frac{n!}{n_1! n_2! \dots n_k!}$ est le **coefficient multinomial**, noté $\binom{n}{n_1, n_2, \dots, n_k}$.

Propriétés de la loi multinomiale :

- Chaque composante X_j (prise isolément) suit une loi binomiale $\mathcal{B}(n, p_j)$.
- Espérance : $\mathbb{E}[X_j] = np_j$.
- Variance : $\text{Var}(X_j) = np_j(1 - p_j)$.
- Covariance : Pour $i \neq j$, $\text{Cov}(X_i, X_j) = -np_i p_j$. (La covariance négative reflète le fait que si une issue se produit plus souvent, les autres doivent se produire moins souvent, puisque la somme des occurrences est fixée à n).

Origine de la formule de la loi multinomiale La probabilité $P(X_1 = n_1, \dots, X_k = n_k)$ est le produit de deux termes :

1. **Le nombre de façons de choisir les positions pour chaque résultat** : Il y a n répétitions de l'expérience. On doit choisir n_1 positions (essais) où l'issue R_1 se produit, puis n_2 positions parmi les $n - n_1$ restantes pour R_2 , et ainsi de suite. Le nombre de façons de partitionner les n essais en k groupes de tailles $n_1, n_2, \dots, n_k$ est donné par le coefficient multinomial :

$$\binom{n}{n_1, n_2, \dots, n_k} = \frac{n!}{n_1! n_2! \dots n_k!}$$

2. **La probabilité d'une séquence spécifique d'observations** : Considérons une séquence particulière d'observations où R_1 apparaît n_1 fois, R_2 apparaît n_2 fois, etc. (par exemple, les n_1 premiers essais donnent R_1 , les n_2 suivants donnent R_2 , etc.). En raison de l'indépendance des n répétitions, la probabilité d'une telle séquence spécifique est $p_1^{n_1} p_2^{n_2} \dots p_k^{n_k}$.

La probabilité totale est le produit du nombre de ces séquences par la probabilité de n'importe laquelle d'entre elles (puisqu'elles sont toutes équiprobables).

4.6 Distributions Conditionnelles

Soient X et Y deux variables aléatoires définies sur le même espace probabilisé. On s'intéresse à la loi de X sachant que Y a pris une certaine valeur y . C'est la "loi de X conditionnellement à $Y = y$ ".

Cas où X, Y sont discrètes : Si $P(Y = y_j) > 0$, la **fonction de masse conditionnelle** de X sachant $Y = y_j$ est :

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)}$$

Pour un y_j fixé, $P(X = x_i | Y = y_j)$ est une fonction de masse en x_i (sa somme sur toutes les valeurs x_i possibles vaut 1). L'**espérance conditionnelle** de $g(X)$ sachant $Y = y_j$ est :

$$\mathbb{E}[g(X) | Y = y_j] = \sum_i g(x_i) P(X = x_i | Y = y_j)$$

Cas où X, Y sont conjointement continues : Si (X, Y) a une densité jointe $f_{X,Y}(x, y)$ et si la densité marginale $f_Y(y) > 0$. La **densité conditionnelle** de X sachant $Y = y$ est définie par :

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

Pour un y fixé, $f_{X|Y=y}(x)$ est une fonction de x et c'est une densité de probabilité (positive et d'intégrale 1 sur $\mathbb{R}$). L'**espérance conditionnelle** de $g(X)$ sachant $Y = y$ est :

$$\mathbb{E}[g(X) | Y = y] = \int_{-\infty}^{+\infty} g(x) f_{X|Y=y}(x) dx$$

Exemple 4.2 (Illustration des distributions conditionnelles - 3 lancers de pièce). Soit X = gain total (Pile = +1€, Face = 0€), $X \in \{0, 1, 2, 3\}$. Soit Y = résultat du 1er lancer (1 si Pile, 0 si Face), $Y \in \{0, 1\}$. Supposons les lancers indépendants et les pièces équilibrées. La loi jointe $P(X = x, Y = y)$ (en 8èmes) a été établie précédemment (voir tableau Section 3.2 - implicitement, car les calculs y mènent). La loi marginale de Y est $P(Y = 0) = 4/8 = 1/2$ et $P(Y = 1) = 4/8 = 1/2$. La loi de X conditionnellement à $Y = 0$ (notée $X|_{Y=0}$) est donnée par $P(X = x | Y = 0) = \frac{P(X=x, Y=0)}{P(Y=0)} : P(X = 0 | Y = 0) = \frac{P(X=0, Y=0)}{1/2}$. Par exemple, si les 3 lancers donnent FFF, $(X = 0, Y = 0)$ a proba 1/8. Donc $P(X = 0 | Y = 0) = (1/8)/(1/2) = 1/4$. De même, $P(X = 1 | Y = 0) = \frac{P(X=1, Y=0)}{1/2}$. L'événement $(X = 1, Y = 0)$ correspond à (F,P,F) ou (F,F,P), proba 2/8. Donc $P(X = 1 | Y = 0) = (2/8)/(1/2) = 1/2$. $P(X = 2 | Y = 0) = \frac{P(X=2, Y=0)}{1/2}$. L'événement $(X = 2, Y = 0)$ correspond à (F,P,P), proba 1/8. Donc $P(X = 2 | Y = 0) = (1/8)/(1/2) = 1/4$. $P(X = 3 | Y = 0) = 0$. (Intuitivement, si le premier lancer est Face ($Y = 0$), le gain X est le nombre de Piles sur les 2 lancers suivants, donc $X|_{Y=0} \sim \mathcal{B}(2, 1/2)$.) De même pour $X|_{Y=1} : P(X = 1 | Y = 1) = 1/4, P(X = 2 | Y = 1) = 1/2, P(X = 3 | Y = 1) = 1/4$. (Intuitivement,




FIGURE 23 – Visualisation de la densité conditionnelle (le profil de coupe est proportionnel à $f_{X|Y=y_0}(x)$).

si le premier lancer est Pile ($Y = 1$), $X = 1 + X'$, où $X' \sim \mathcal{B}(2, 1/2)$ est le nombre de Piles sur les 2 lancers suivants.)

Expérience aléatoire avec une probabilité de succès p inconnue (Introduction à l'Inférence Bayésienne) On s'intéresse à un paramètre inconnu p (par exemple, la probabilité de succès d'une expérience de Bernoulli). Dans l'approche bayésienne, on traite p comme une variable aléatoire, dotée d'une distribution a priori (reflétant notre croyance sur p avant toute observation). Supposons un a priori uniforme pour p sur $[0, 1]$: $P \sim \mathcal{U}([0, 1])$, donc sa densité $f_P(p) = 1$ pour $p \in [0, 1]$. On réalise ensuite $N_{tot} = n + m$ fois l'expérience et on observe n succès et m échecs. On souhaite mettre à jour notre croyance sur p en calculant sa distribution a posteriori, conditionnellement aux données observées. La vraisemblance d'observer n succès et m échecs, si la probabilité de succès est p , est donnée par la loi binomiale : $L(\text{données}|p) = \binom{n+m}{n} p^n (1-p)^m$. Par le théorème de Bayes (version continue pour les densités) : $f_{P|\text{données}}(p|\text{données}) \propto L(\text{données}|p) f_P(p)$. $f_{P|\text{données}}(p|n \text{ succès}, m \text{ échecs}) \propto p^n (1-p)^m \cdot 1$ (pour $p \in [0, 1]$). La densité a posteriori est donc de la forme $C \cdot p^n (1-p)^m$. C'est la densité d'une loi Beta, plus précisément $\text{Beta}(n+1, m+1)$. La constante C est la constante de normalisation $1/B(n+1, m+1)$, où B est la fonction Beta.

4.7 Espérance Conditionnelle comme Variable Aléatoire

Jusqu'à présent, $\mathbb{E}[X|Y = y]$ était un nombre (ou une fonction de la valeur y). On peut définir $\mathbb{E}[X|Y]$ comme une **variable aléatoire**. C'est une fonction de la variable aléatoire Y , et donc elle-même une variable aléatoire. On la note souvent $h(Y)$, où la fonction h est définie par $h(y_j) = \mathbb{E}[X|Y = y_j]$ dans le cas discret (ou $h(y) = \mathbb{E}[X|Y = y]$ dans le cas continu). Cette variable aléatoire $\mathbb{E}[X|Y]$ prend la valeur $\mathbb{E}[X|Y = y]$ lorsque l'événement $\{Y = y\}$ se réalise.

Définition 4.3 (Espérance Conditionnelle $\mathbb{E}[X|Y]$). (formelle)] L'espérance conditionnelle $\mathbb{E}[X|Y]$ de X sachant Y




FIGURE 24 – Inférence Bayésienne : A priori $\mathcal{U}(0, 1)$, 3 succès et 2 échecs ($n = 3, m = 2$). La vraisemblance (non normalisée) est $p^3(1 - p)^2$. L'a posteriori est $\text{Beta}(4, 3)$.

Z est $\sigma(Y)$ -mesurable (intuitivement, Z est une fonction de Y , $Z = h(Y)$, et ne dépend que de l'information apportée par Y).

Pour tout événement $A \in \sigma(Y)$ (c'est-à-dire, tout événement dont la réalisation ou non ne dépend que de Y , typiquement $A = \{Y \in B\}$ pour un borélien B), on a :

$$\mathbb{E}[Z \cdot \mathbb{1}_A] = \mathbb{E}[X \cdot \mathbb{1}_A]$$

où $\mathbb{1}_A$ est la fonction indicatrice de A .

Cette définition est plus abstraite et générale. Elle stipule que $\mathbb{E}[X|Y]$ est la "meilleure approximation" de X en termes de variables aléatoires qui sont fonctions de Y (au sens de la projection orthogonale dans l'espace L^2 si les variables sont de carré intégrable).

Proposition 4.4 (Propriétés de l'espérance conditionnelle $\mathbb{E}[X|Y]$).]Soient X, X_1, X_2, Y des variables aléatoires et $a, b \in \mathbb{R}$.

1. **Linéarité** : $\mathbb{E}[aX_1 + bX_2|Y] = a\mathbb{E}[X_1|Y] + b\mathbb{E}[X_2|Y]$ (p.s.).
2. **Espérance d'une constante** : Si c est une constante, $\mathbb{E}[c|Y] = c$ (p.s.).
3. **Sortir ce qui est $\sigma(Y)$ -mesurable ("connu sachant Y ")** : Si g est une fonction mesurable telle que $g(Y)$ soit une v.a. bien définie, alors $\mathbb{E}[g(Y)X|Y] = g(Y)\mathbb{E}[X|Y]$ (p.s.). En particulier, $\mathbb{E}[g(Y)|Y] = g(Y)$ (p.s.).
4. **Indépendance** : Si $X \perp\!\!\!\perp Y$, alors $\mathbb{E}[X|Y] = \mathbb{E}[X]$ (p.s.). (La connaissance de Y n'apporte aucune information sur X).
5. **Espérance itérée (Tower property / Loi de l'espérance totale)** :

$$\mathbb{E}[\mathbb{E}[X|Y]] = \mathbb{E}[X]$$

C'est une propriété fondamentale et très utile pour calculer des espérances en conditionnant.

Exemple 4.5 (Produit de convolution). Si $X \perp\!\!\!\perp Y$ sont deux variables aléatoires continues indépendantes, et $Z = X + Y$. On veut trouver la densité $f_Z(z)$. On peut utiliser la loi de l'espérance totale pour la fonction de répartition $F_Z(z) = P(X + Y \leq z) = \mathbb{E}[\mathbb{1}_{X+Y \leq z}]$. $F_Z(z) = \mathbb{E}[\mathbb{E}[\mathbb{1}_{X+Y \leq z}|Y]]$. L'espérance intérieure est $\mathbb{E}[\mathbb{1}_{X+Y \leq z}|Y = y] = P(X + y \leq z|Y = y) =$

$P(X \leq z - y | Y = y)$. Par indépendance de X et Y , $P(X \leq z - y | Y = y) = P(X \leq z - y) = F_X(z - y)$. Donc, l'espérance conditionnelle $\mathbb{E}[\mathbf{1}_{X+Y \leq z} | Y]$ est la variable aléatoire $F_X(z - Y)$. Ainsi, $F_Z(z) = \mathbb{E}[F_X(z - Y)] = \int_{-\infty}^{+\infty} F_X(z - y) f_Y(y) dy$. Pour obtenir la densité $f_Z(z) = \frac{d}{dz} F_Z(z)$, en dérivant sous le signe intégral (sous conditions de régularité) :

$$f_Z(z) = \int_{-\infty}^{+\infty} \left(\frac{d}{dz} F_X(z - y) \right) f_Y(y) dy = \int_{-\infty}^{+\infty} f_X(z - y) f_Y(y) dy$$

C'est la formule du **produit de convolution** des densités f_X et f_Y , noté $(f_X * f_Y)(z)$.

5 Inégalités, Convergences et Théorème Limite

5.1 Inégalités de Probabilités

Ces inégalités fournissent des bornes sur les probabilités sans connaître la loi exacte de la variable aléatoire, seulement certains de ses moments (comme l'espérance ou la variance).

5.1.1 Inégalité de Markov

Soit X une variable aléatoire telle que $\mathbb{E}[|X|]$ existe et est finie. Alors, pour tout $a > 0$:

$$P(|X| \geq a) \leq \frac{\mathbb{E}[|X|]}{a}$$

Si X est une variable aléatoire **positive** ($X \geq 0$ p.s.), l'inégalité s'écrit plus simplement :

$$P(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

Exemple 5.1. Dans un pays, le salaire moyen est $m = \mathbb{E}[X]$. La proportion des gens qui gagnent au moins 5 fois le salaire moyen est $P(X \geq 5m)$. D'après Markov (car les salaires X sont positifs) : $P(X \geq 5m) \leq \frac{\mathbb{E}[X]}{5m} = \frac{m}{5m} = \frac{1}{5} = 20\%$. Ainsi, au plus 20% de la population gagne 5 fois ou plus le salaire moyen.

Remarque 5.2 (Saturation de l'inégalité de Markov). L'inégalité de Markov est souvent une borne assez grossière, mais elle est universelle. Elle peut être "saturée" (c'est-à-dire devenir une égalité) pour certaines distributions. Par exemple, si X est une v.a. telle que $X = a$ avec probabilité p et $X = 0$ avec probabilité $1 - p$. Alors $\mathbb{E}[X] = ap$. L'inégalité de Markov donne $P(X \geq a) \leq \frac{ap}{a} = p$. Or, $P(X \geq a) = P(X = a) = p$. Donc l'égalité est atteinte.

Démonstration de l'inégalité de Markov (pour $X \geq 0$). Considérons la variable indicatrice $\mathbb{1}_{X \geq a}$. Puisque $X \geq 0$ et $a > 0$: Si $X < a$, alors $a \cdot \mathbb{1}_{X \geq a} = a \cdot 0 = 0 \leq X$. Si $X \geq a$, alors $a \cdot \mathbb{1}_{X \geq a} = a \cdot 1 = a \leq X$. Donc, dans tous les cas, $a \cdot \mathbb{1}_{X \geq a} \leq X$. En prenant l'espérance des deux côtés (par monotonie de l'espérance) : $\mathbb{E}[a \cdot \mathbb{1}_{X \geq a}] \leq \mathbb{E}[X]$. $a\mathbb{E}[\mathbb{1}_{X \geq a}] \leq \mathbb{E}[X]$. Comme $\mathbb{E}[\mathbb{1}_{X \geq a}] = P(X \geq a)$, on a $aP(X \geq a) \leq \mathbb{E}[X]$. D'où $P(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$. La preuve pour $P(|X| \geq a)$ est similaire en appliquant le résultat à la v.a. positive $|X|$. $\square$

Corollaire 5.3 (Généralisation de Markov). Soit X une variable aléatoire. Soit $\varphi : \mathbb{R} \rightarrow \mathbb{R}^+$ une fonction positive et **croissante** sur le support de X (ou du moins pour les valeurs $\geq a_0$ pour un certain a_0). Alors pour tout a tel que $\varphi(a) > 0$:

$$P(X \geq a) \leq \frac{\mathbb{E}[\varphi(X)]}{\varphi(a)}$$

(En supposant que $\mathbb{E}[\varphi(X)]$ existe).

Démonstration. Si $X \geq a$, alors comme φ est croissante, $\varphi(X) \geq \varphi(a)$. Donc, l'événement $\{X \geq a\}$ est inclus dans l'événement $\{\varphi(X) \geq \varphi(a)\}$. Par conséquent, $P(X \geq a) \leq P(\varphi(X) \geq \varphi(a))$. Appliquons maintenant l'inégalité de Markov à la variable aléatoire positive $Y = \varphi(X)$ et à

la constante positive $b = \varphi(a) : P(\varphi(X) \geq \varphi(a)) \leq \frac{\mathbb{E}[\varphi(X)]}{\varphi(a)}$. Le résultat $P(X \geq a) \leq \frac{\mathbb{E}[\varphi(X)]}{\varphi(a)}$ suit. $\square$

5.1.2 Inégalité de Bienaymé-Tchebychev

Soit X une variable aléatoire ayant une espérance $\mathbb{E}[X] = \mu$ et une variance $\text{Var}(X) = \sigma^2$ finie (donc $\sigma^2 < \infty$). Pour tout $a > 0$:

$$P(|X - \mu| \geq a) \leq \frac{\text{Var}(X)}{a^2} = \frac{\sigma^2}{a^2}$$

Cette inégalité donne une borne à la probabilité que X s'écarte de sa moyenne μ d'une quantité au moins égale à a . Une forme équivalente, souvent utilisée, est obtenue en posant $a = k\sigma$ (où $k > 0$ représente le nombre d'écarts-types) :

$$P(|X - \mu| \geq k\sigma) \leq \frac{\sigma^2}{(k\sigma)^2} = \frac{1}{k^2}$$

Par exemple, la probabilité de s'écarter de plus de 2 écarts-types de la moyenne est au plus $1/2^2 = 1/4 = 25\%$. La probabilité de s'écarter de plus de 3 écarts-types de la moyenne est au plus $1/3^2 = 1/9 \approx 11\%$.

Démonstration. On applique l'inégalité de Markov à la variable aléatoire $Y = (X - \mu)^2$. Y est une variable aléatoire positive (car c'est un carré). Son espérance est $\mathbb{E}[Y] = \mathbb{E}[(X - \mu)^2] = \text{Var}(X)$. L'événement $\{|X - \mu| \geq a\}$ est équivalent à l'événement $\{(X - \mu)^2 \geq a^2\}$ (puisque $a > 0$ et la fonction carré est croissante pour les valeurs positives). Donc, $P(|X - \mu| \geq a) = P((X - \mu)^2 \geq a^2)$. En appliquant l'inégalité de Markov à $Y = (X - \mu)^2$ et à la constante $a^2 (> 0)$:

$$P((X - \mu)^2 \geq a^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{a^2} = \frac{\text{Var}(X)}{a^2}$$

Ce qui prouve l'inégalité. $\square$

L'inégalité de Tchebychev est universelle (elle ne dépend pas de la loi spécifique de X , seulement de son espérance et de sa variance), mais elle est souvent une borne peu précise. Pour des lois spécifiques (comme la loi normale), les bornes réelles sont bien meilleures.

5.1.3 Inégalité de Jensen

Soit X une variable aléatoire telle que son espérance $\mathbb{E}[X]$ existe et est finie. Soit I un intervalle de $\mathbb{R}$ tel que $P(X \in I) = 1$ (c'est-à-dire que X prend ses valeurs dans I presque sûrement). Soit $\varphi : I \rightarrow \mathbb{R}$ une fonction **convexe** sur l'intervalle I . Si $\mathbb{E}[X]$ et $\mathbb{E}[\varphi(X)]$ existent, alors :

$$\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)]$$

Si φ est **concave** sur I , alors l'inégalité est inversée : $\varphi(\mathbb{E}[X]) \geq \mathbb{E}[\varphi(X)]$.

Rappel sur les fonctions convexes : Une fonction $\varphi : I \rightarrow \mathbb{R}$ est convexe si pour tous $x, y \in I$ et tout $t \in [0, 1]$: $\varphi(tx + (1-t)y) \leq t\varphi(x) + (1-t)\varphi(y)$. (Géométriquement, le segment de droite joignant deux points de la courbe est au-dessus de la courbe). Si φ est deux fois dérivable sur I , φ est convexe $\iff \varphi''(x) \geq 0$ pour tout $x \in I$. Une propriété clé des fonctions convexes (si φ est dérivable) : la courbe de φ est au-dessus de toutes ses tangentes. Pour tout $x_0 \in I$, $\varphi(x) \geq \varphi(x_0) + \varphi'(x_0)(x - x_0)$ pour tout $x \in I$.

Démonstration (cas où φ' existe). Puisque φ est convexe, pour tout $x_0 \in I$, on a l'inégalité de la tangente : $\varphi(x) \geq \varphi(x_0) + \varphi'(x_0)(x - x_0)$ pour tout $x \in I$. Choisissons $x_0 = \mathbb{E}[X]$. On suppose que $\mathbb{E}[X] \in I$ (ce qui est vrai si I est un intervalle convexe et X prend ses valeurs dans I). Alors, pour la variable aléatoire X (qui prend ses valeurs dans I p.s.) :

$$\varphi(X) \geq \varphi(\mathbb{E}[X]) + \varphi'(\mathbb{E}[X])(X - \mathbb{E}[X]) \quad (\text{p.s.})$$

Ceci est une inégalité entre variables aléatoires. En prenant l'espérance des deux côtés (par monotonie de l'espérance) :

$$\mathbb{E}[\varphi(X)] \geq \mathbb{E}[\varphi(\mathbb{E}[X]) + \varphi'(\mathbb{E}[X])(X - \mathbb{E}[X])]$$

Par linéarité de l'espérance :

$$\mathbb{E}[\varphi(X)] \geq \mathbb{E}[\varphi(\mathbb{E}[X])] + \mathbb{E}[\varphi'(\mathbb{E}[X])(X - \mathbb{E}[X])]$$

Puisque $\mathbb{E}[X]$ est une constante, $\varphi(\mathbb{E}[X])$ et $\varphi'(\mathbb{E}[X])$ sont aussi des constantes. Donc $\mathbb{E}[\varphi(\mathbb{E}[X])] = \varphi(\mathbb{E}[X])$. Et $\mathbb{E}[\varphi'(\mathbb{E}[X])(X - \mathbb{E}[X])] = \varphi'(\mathbb{E}[X])\mathbb{E}[X - \mathbb{E}[X]]$. Or, $\mathbb{E}[X - \mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[\mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[X] = 0$. Ainsi, le deuxième terme du membre de droite est nul. On obtient :

$$\mathbb{E}[\varphi(X)] \geq \varphi(\mathbb{E}[X])$$

Ce qui est l'inégalité de Jensen. □




FIGURE 25 – Une fonction convexe est au-dessus de ses tangentes : $\varphi(x) \geq \varphi(x_0) + \varphi'(x_0)(x - x_0)$

Exemple 5.4 (Application de l'inégalité de Jensen au choix d'investissement). On a le choix entre deux investissements :

1. Un investissement sans risque, de retour certain C euros.

2. Un investissement risqué, dont le retour est une variable aléatoire X avec une espérance de gain $\mathbb{E}[X] = C$.

Quel investissement choisir ? Cela dépend de la **fonction d'utilité** $u : \mathbb{R} \rightarrow \mathbb{R}$ de l'investisseur, qui mesure la satisfaction (utilité) retirée d'un gain x . On suppose que u est croissante (plus on gagne, plus on est satisfait).

- Si u est **convexe** (investisseur aimant le risque / risk-loving) : Par Jensen, $u(C) = u(\mathbb{E}[X]) \leq \mathbb{E}[u(X)]$. L'utilité de l'investissement certain $u(C)$ est inférieure ou égale à l'utilité espérée de l'investissement risqué $\mathbb{E}[u(X)]$. $\implies$ L'investisseur peut préférer l'option risquée.
- Si u est **concave** (investisseur averse au risque / risk-averse) : Par Jensen (pour une fonction concave, l'inégalité est inversée), $u(C) = u(\mathbb{E}[X]) \geq \mathbb{E}[u(X)]$. L'utilité de l'investissement certain $u(C)$ est supérieure ou égale à l'utilité espérée de l'investissement risqué $\mathbb{E}[u(X)]$. $\implies$ L'investisseur préfère l'option sans risque.
- Si u est **linéaire** (investisseur neutre au risque, e.g., $u(x) = ax + b$ avec $a > 0$) : $u(\mathbb{E}[X]) = a\mathbb{E}[X] + b = \mathbb{E}[aX + b] = \mathbb{E}[u(X)]$. L'investisseur est indifférent entre les deux options si elles ont la même espérance de gain.



FIGURE 26 – Fonctions d'utilité convexe (aimant le risque) et concave (averse au risque)

5.2 Convergences de Suites de Variables Aléatoires

Soit $(X_n)_{n \in \mathbb{N}}$ une suite de variables aléatoires et X une autre variable aléatoire. Sauf indication contraire, elles sont toutes définies sur le même espace probabilisé $(\Omega, \mathcal{A}, P)$. La convergence en distribution est une exception et ne requiert pas que les v.a. soient sur le même espace.

5.2.1 Convergence en Distribution (ou en Loi)

Notée $X_n \xrightarrow{d} X$ ou $X_n \xrightarrow{\mathcal{L}} X$.

Définition 5.5. La suite $(X_n)_{n \in \mathbb{N}}$ **converge en distribution** (ou **en loi**) vers X si :

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$$

en tout point $x \in \mathbb{R}$ où la fonction de répartition F_X de X est continue.

Exemple 5.6 ($X_n = \max(U_1, \dots, U_n)$ avec $U_i \sim \mathcal{U}([0, a])$.)i.i.d.] $F_U(x) = x/a$ pour $x \in [0, a]$.
 $F_{X_n}(x) = P(\max(U_i) \leq x) = P(U_1 \leq x, \dots, U_n \leq x) = (F_U(x))^n = (x/a)^n$ pour $x \in [0, a]$.

Ailleurs, $F_{X_n}(x) = 0$ si $x < 0$ et $F_{X_n}(x) = 1$ si $x > a$. Quand $n \rightarrow \infty$: Si $0 \leq x < a$, alors $x/a < 1$, donc $(x/a)^n \rightarrow 0$. Si $x = a$, alors $(a/a)^n = 1^n \rightarrow 1$. Si $x > a$, $F_{X_n}(x) = 1 \rightarrow 1$. Si $x < 0$, $F_{X_n}(x) = 0 \rightarrow 0$. Donc, $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_a(x) = \begin{cases} 0 & \text{si } x < a \\ 1 & \text{si } x \geq a \end{cases}$. C'est la fonction de répartition d'une variable aléatoire constante égale à a . Ainsi, $X_n \xrightarrow{d} a$.

Proposition 5.7 (Propriétés de la convergence en distribution). Soit $X_n \xrightarrow{d} X$.

1. **Théorème de Portmanteau (une implication) / Théorème de la continuité de l'espérance** : Si $f : \mathbb{R} \rightarrow \mathbb{R}$ est une fonction continue et **bornée**, alors $\mathbb{E}[f(X_n)] \xrightarrow{n \rightarrow \infty} \mathbb{E}[f(X)]$.
2. **Continuous Mapping Theorem (CMT)** : Si $g : \mathbb{R} \rightarrow \mathbb{R}$ est une fonction continue (plus précisément, continue en dehors d'un ensemble D_g de points de discontinuité tel que $P(X \in D_g) = 0$), alors $g(X_n) \xrightarrow{d} g(X)$.

Remarque 5.8 (Limitations de la convergence en distribution). 1. Les v.a. X_n et X n'ont pas besoin d'être définies sur le même espace probabilisé.

2. Si $X_n \xrightarrow{d} X$ et $Y_n \xrightarrow{d} Y$, on n'a pas en général $X_n + Y_n \xrightarrow{d} X + Y$, sauf si une des limites est une constante (voir Lemme de Slutsky).

5.2.2 Convergence en Probabilité

Notée $X_n \xrightarrow{P} X$. (Nécessite que X_n et X soient sur le même espace probabilisé).

Définition 5.9. La suite $(X_n)_{n \in \mathbb{N}}$ **converge en probabilité** vers X si pour tout $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$$

(ou de manière équivalente, $\lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0$).

Exemple 5.10 (Suite de $X_n = \max(U_i)$ avec $U_i \sim \mathcal{U}([0, a])$). On a vu $X_n \xrightarrow{d} a$. Montrons que $X_n \xrightarrow{P} a$. Pour $0 < \varepsilon < a$: $P(|X_n - a| > \varepsilon) = P(a - X_n > \varepsilon) = P(X_n < a - \varepsilon) = F_{X_n}(a - \varepsilon) = \left(\frac{a - \varepsilon}{a}\right)^n$. Comme $0 < \frac{a - \varepsilon}{a} < 1$, $\lim_{n \rightarrow \infty} \left(\frac{a - \varepsilon}{a}\right)^n = 0$. Donc $X_n \xrightarrow{P} a$.

Proposition 5.11 (Propriétés de la convergence en probabilité). Soit $X_n \xrightarrow{P} X$ et $Y_n \xrightarrow{P} Y$.

1. **Unicité de la limite (p.s.)** : Si $X_n \xrightarrow{P} X$ et $X_n \xrightarrow{P} X'$, alors $X = X'$ p.s.
2. **Stabilité par opérations algébriques** (Lemme de Slutsky partiel) : $X_n + Y_n \xrightarrow{P} X + Y$, $X_n Y_n \xrightarrow{P} XY$. Si $Y \neq 0$ p.s., $X_n/Y_n \xrightarrow{P} X/Y$.
3. **Continuous Mapping Theorem (CMT)** : Si $g : \mathbb{R} \rightarrow \mathbb{R}$ est continue, alors $g(X_n) \xrightarrow{P} g(X)$.

5.2.3 Convergence Presque Sûre

Notée $X_n \xrightarrow{p.s.} X$ ou $X_n \xrightarrow{a.s.} X$. (Nécessite X_n, X sur le même espace).

Définition 5.12. La suite $(X_n)_{n \in \mathbb{N}}$ **converge presque sûrement** vers X si :

$$P(\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\}) = 1$$

C'est la convergence de la suite de fonctions $X_n(\cdot)$ vers $X(\cdot)$ sur un ensemble de mesure 1.

Une condition suffisante, via le premier lemme de Borel-Cantelli, est : Si $\sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < \infty$ pour tout $\varepsilon > 0$, alors $X_n \xrightarrow{p.s.} X$.

Exemple 5.13 (Suite de $X_n = \max(U_i)$ avec $U_i \sim \mathcal{U}([0, a])$.) On a $P(|X_n - a| > \varepsilon) = (\frac{a-\varepsilon}{a})^n$. La série $\sum_{n=1}^{\infty} (\frac{a-\varepsilon}{a})^n$ est une série géométrique de raison $r = \frac{a-\varepsilon}{a} \in [0, 1)$. Elle converge. Par la condition de Borel-Cantelli, $X_n \xrightarrow{p.s.} a$.

Proposition 5.14 (Propriétés de la convergence presque sûre). Unicité de la limite (p.s.). Stabilité par opérations algébriques. CMT si g continue : $g(X_n) \xrightarrow{p.s.} g(X)$.

5.2.4 Convergence en Moyenne (d'ordre r ou en L^r)

Notée $X_n \xrightarrow{L^r} X$. (Nécessite X_n, X sur le même espace).

Définition 5.15. Soit $r \geq 1$. La suite $(X_n)_{n \in \mathbb{N}}$ **converge en moyenne d'ordre r** vers X , si $\mathbb{E}[|X_n|^r] < \infty$ pour tout n , $\mathbb{E}[|X|^r] < \infty$, et :

$$\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|^r] = 0$$

Cas importants :

- $r = 1$: Convergence en moyenne. $\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|] = 0$.
- $r = 2$: Convergence en moyenne quadratique. $\lim_{n \rightarrow \infty} \mathbb{E}[(X_n - X)^2] = 0$.

Exemple 5.16 (Suite de $X_n = \max(U_i)$ avec $U_i \sim \mathcal{U}([0, a])$.) Calcul de $\mathbb{E}[X_n] = \frac{na}{n+1}$. $\mathbb{E}[|X_n - a|] = \mathbb{E}[a - X_n]$ (car $X_n \leq a$) $= a - \mathbb{E}[X_n] = a - \frac{na}{n+1} = \frac{a}{n+1}$. Comme $\lim_{n \rightarrow \infty} \frac{a}{n+1} = 0$, on a $X_n \xrightarrow{L^1} a$.

5.3 Comparaisons des modes de convergence

Voici les principales implications entre les modes de convergence :

- **Convergence presque sûre $\implies$ Convergence en probabilité : $X_n \xrightarrow{p.s.} X \implies X_n \xrightarrow{P} X$.
- **Convergence en moyenne L^r ($r \geq 1$) $\implies$ Convergence en probabilité : $X_n \xrightarrow{L^r} X \implies X_n \xrightarrow{P} X$. (Se démontre avec l'inégalité de Markov appliquée à $|X_n - X|^r$).
- **Convergence en probabilité $\implies$ Convergence en distribution : $X_n \xrightarrow{P} X \implies X_n \xrightarrow{d} X$.
- **Convergence en moyenne $L^r \implies$ Convergence en moyenne L^s (pour $r \geq s \geq 1$) : Si $X_n \xrightarrow{L^r} X$, alors $X_n \xrightarrow{L^s} X$ pour tout $1 \leq s \leq r$. (Par l'inégalité de Lyapounov ou Jensen).

Les réciproques sont généralement fausses sans conditions supplémentaires. Quelques réciproques (ou liens supplémentaires) notables :




FIGURE 27 – Relations entre les modes de convergence.

- Si $X_n \xrightarrow{d} c$ (où c est une constante), alors $X_n \xrightarrow{P} c$. (Partie du Lemme de Slutsky).
- Si $X_n \xrightarrow{P} X$, alors il existe une sous-suite $(X_{n_k})_{k \in \mathbb{N}}$ telle que $X_{n_k} \xrightarrow{p.s.} X$.
- Si $X_n \xrightarrow{P} X$ et la suite (X_n) est dominée par une variable aléatoire $Y \in L^r$ (c'est-à-dire $|X_n| \leq Y$ p.s. pour tout n , et $\mathbb{E}[Y^r] < \infty$), alors $X_n \xrightarrow{L^r} X$. (Conséquence du Théorème de la convergence dominée de Lebesgue).

5.4 Fonction Caractéristique

La fonction caractéristique est un outil puissant en probabilités, notamment pour étudier les sommes de variables aléatoires indépendantes et pour prouver la convergence en distribution (comme dans le TCL).

Définition 5.17 (Fonction caractéristique). Soit X une variable aléatoire réelle. Sa **fonction caractéristique** est une fonction $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ (à valeurs complexes) définie par :

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \mathbb{E}[\cos(tX) + i \sin(tX)] = \mathbb{E}[\cos(tX)] + i\mathbb{E}[\sin(tX)]$$

où $i^2 = -1$ et $t \in \mathbb{R}$. La fonction caractéristique existe toujours pour toute variable aléatoire, car $|e^{itX}| = 1$, donc $\mathbb{E}[|e^{itX}|] = \mathbb{E}[1] = 1 < \infty$.

Remarque 5.18 (Propriétés de la fonction caractéristique). 1. $\varphi_X(0) = \mathbb{E}[e^{i \cdot 0 \cdot X}] = \mathbb{E}[1] = 1$.

2. $|\varphi_X(t)| = |\mathbb{E}[e^{itX}]| \leq \mathbb{E}[|e^{itX}|] = \mathbb{E}[1] = 1$. La fonction caractéristique est bornée par 1.

3. $\varphi_X(-t) = \mathbb{E}[e^{-itX}] = \mathbb{E}[\overline{e^{itX}}] = \overline{\mathbb{E}[e^{itX}]} = \overline{\varphi_X(t)}$ (conjugué complexe).

4. Transformation affine : $\varphi_{aX+b}(t) = \mathbb{E}[e^{it(aX+b)}] = \mathbb{E}[e^{itaX} e^{itb}] = e^{itb} \mathbb{E}[e^{i(at)X}] = e^{itb} \varphi_X(at)$.

5. La fonction caractéristique $\varphi_X(t)$ est uniformément continue sur $\mathbb{R}$.

6. **Lien avec les moments** : Si $\mathbb{E}[|X|^k] < \infty$ pour un entier $k \geq 1$ (i.e., X admet un moment d'ordre k), alors φ_X est k fois continûment dérivable sur $\mathbb{R}$, et sa j -ième dérivée en 0 est liée au j -ième moment de X (pour $j \leq k$) :

$$\varphi_X^{(j)}(t) = \mathbb{E}[(iX)^j e^{itX}]$$

En particulier, en $t = 0$: $\varphi_X^{(j)}(0) = \mathbb{E}[(iX)^j] = i^j \mathbb{E}[X^j]$. Donc, $\mathbb{E}[X^j] = \frac{\varphi_X^{(j)}(0)}{i^j} = (-i)^j \varphi_X^{(j)}(0)$. Par exemple : $\mathbb{E}[X] = \frac{\varphi_X'(0)}{i} = -i\varphi_X'(0)$, et $\mathbb{E}[X^2] = \frac{\varphi_X''(0)}{i^2} = -\varphi_X''(0)$. Cela permet d'obtenir un développement limité de $\varphi_X(t)$ autour de $t = 0$ si les moments existent : Si $\mathbb{E}[|X|^k] < \infty$, alors $\varphi_X(t) = \sum_{j=0}^k \frac{\mathbb{E}[X^j](it)^j}{j!} + o(t^k)$ quand $t \rightarrow 0$.

Proposition 5.19 (Unicité et Théorème de continuité de Lévy). 1. **Théorème d'unicité** :

Deux variables aléatoires X et Y ont la même loi de probabilité (c'est-à-dire $F_X(x) = F_Y(x)$ pour tout x) si et seulement si elles ont la même fonction caractéristique ($\varphi_X(t) = \varphi_Y(t)$ pour tout $t \in \mathbb{R}$). La fonction caractéristique caractérise donc la loi.

2. **Théorème de continuité de Lévy** : Soit $(X_n)_{n \in \mathbb{N}}$ une suite de variables aléatoires. $X_n \xrightarrow{d} X$ si et seulement si $\varphi_{X_n}(t) \xrightarrow{n \rightarrow \infty} \varphi_X(t)$ pour tout $t \in \mathbb{R}$ (convergence simple des fonctions caractéristiques), et si la fonction limite $\varphi(t) = \lim \varphi_{X_n}(t)$ est continue en $t = 0$ (ce qui est automatiquement vrai si $\varphi(t)$ est elle-même une fonction caractéristique).

Proposition 5.20 (Fonction caractéristique d'une somme de v.a. indépendantes). Si $X_1, X_2, \dots, X_n$ sont des variables aléatoires **mutuellement indépendantes**, alors la fonction caractéristique de leur somme $S_n = X_1 + \dots + X_n$ est le produit de leurs fonctions caractéristiques individuelles :

$$\varphi_{S_n}(t) = \prod_{j=1}^n \varphi_{X_j}(t)$$

Exemple 5.21 (Fonctions caractéristiques usuelles). — Si $Z \sim \mathcal{N}(0, 1)$, alors $\varphi_Z(t) = e^{-t^2/2}$.

— Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $X = \sigma Z + \mu$ avec $Z \sim \mathcal{N}(0, 1)$. Donc $\varphi_X(t) = \varphi_{\sigma Z + \mu}(t) = e^{it\mu} \varphi_Z(\sigma t) = e^{it\mu} e^{-(\sigma t)^2/2} = e^{it\mu - \sigma^2 t^2/2}$.

— Application : Si $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ sont indépendantes, alors $S = X_1 + X_2$. $\varphi_S(t) = \varphi_{X_1}(t) \varphi_{X_2}(t) = e^{it(\mu_1 + \mu_2) - (\sigma_1^2 + \sigma_2^2)t^2/2}$. C'est la f.c. d'une $\mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

5.5 Théorèmes Limites

5.5.1 Théorème Central Limite (TCL) - Version de Lindeberg-Lévy

Soient $X_1, X_2, \dots$ une suite de variables aléatoires **indépendantes et identiquement distribuées (i.i.d.)** ayant une espérance commune $\mathbb{E}[X_i] = \mu < \infty$ et une variance commune $\text{Var}(X_i) = \sigma^2 \in (0, \infty)$ (finie et strictement positive). Soit $S_n = X_1 + \dots + X_n$ la somme partielle. Soit $\bar{X}_n = \frac{S_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$ la moyenne empirique. On a $\mathbb{E}[S_n] = n\mu$, $\text{Var}(S_n) = n\sigma^2$ (par indépendance). Et $\mathbb{E}[\bar{X}_n] = \mu$, $\text{Var}(\bar{X}_n) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$.

Le TCL stipule que la somme (ou la moyenne) standardisée (centrée et réduite) converge en

distribution vers une loi normale centrée réduite :

$$Z_n = \frac{S_n - \mathbb{E}[S_n]}{\sqrt{\text{Var}(S_n)}} = \frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

De manière équivalente pour la moyenne empirique :

$$\frac{\bar{X}_n - \mathbb{E}[\bar{X}_n]}{\sqrt{\text{Var}(\bar{X}_n)}} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Cela signifie que pour n suffisamment grand, la distribution de S_n peut être approximée par une loi $\mathcal{N}(n\mu, n\sigma^2)$, et celle de $\bar{X}_n$ par une loi $\mathcal{N}(\mu, \sigma^2/n)$.

Idée de la preuve du TCL (via les fonctions caractéristiques). Pour simplifier, on suppose X_i i.i.d. avec $\mathbb{E}[X_i] = 0$ et $\text{Var}(X_i) = 1$ (sinon, on travaille avec $Y_i = (X_i - \mu)/\sigma$). Alors $\mathbb{E}[X_i^2] = 1$. On s'intéresse à $Z_n = \frac{S_n}{\sqrt{n}} = \sum_{i=1}^n \frac{X_i}{\sqrt{n}}$. $\varphi_{Z_n}(t) = \mathbb{E}[e^{itS_n/\sqrt{n}}] = \mathbb{E}[\prod_{i=1}^n e^{itX_i/\sqrt{n}}] = \prod_{i=1}^n \mathbb{E}[e^{itX_i/\sqrt{n}}]$ (par indépendance). Comme les X_i sont i.i.d., $\varphi_{X_i/\sqrt{n}}(t) = \varphi_{X_1}(t/\sqrt{n})$. Donc $\varphi_{Z_n}(t) = (\varphi_{X_1}(t/\sqrt{n}))^n$. On utilise le développement limité de $\varphi_{X_1}(u)$ autour de $u = 0$ à l'ordre 2 (car $\mathbb{E}[X_1] = 0, \mathbb{E}[X_1^2] = 1$) : $\varphi_{X_1}(u) = \varphi_{X_1}(0) + u\varphi'_{X_1}(0) + \frac{u^2}{2}\varphi''_{X_1}(0) + o(u^2) = 1 + u(i\mathbb{E}[X_1]) + \frac{u^2}{2}(i^2\mathbb{E}[X_1^2]) + o(u^2) = 1 + 0 - \frac{u^2}{2} + o(u^2)$. En posant $u = t/\sqrt{n}$: $\varphi_{X_1}(t/\sqrt{n}) = 1 - \frac{(t/\sqrt{n})^2}{2} + o((t/\sqrt{n})^2) = 1 - \frac{t^2}{2n} + o(1/n)$. Alors $\varphi_{Z_n}(t) = \left(1 - \frac{t^2}{2n} + o(1/n)\right)^n$. En utilisant le fait que si $a_n \rightarrow a$, alors $(1 + a_n/n)^n \rightarrow e^a$. Ici, avec $a_n = -t^2/2 + n \cdot o(1/n)$, on a $a_n \rightarrow -t^2/2$. Donc $\lim_{n \rightarrow \infty} \varphi_{Z_n}(t) = e^{-t^2/2}$. C'est la fonction caractéristique d'une loi $\mathcal{N}(0, 1)$. Par le théorème de continuité de Lévy, $Z_n \xrightarrow{d} \mathcal{N}(0, 1)$. $\square$

5.5.2 Loi Faible des Grands Nombres (LFGN)

Soient $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. avec une espérance commune $\mathbb{E}[X_i] = \mu < \infty$. (La loi faible des grands nombres (version de Khintchine) ne requiert pas de variance finie. La preuve suivante suppose une variance finie pour simplifier). Alors la moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ converge en probabilité vers μ :

$$\bar{X}_n \xrightarrow{P} \mu$$

C'est-à-dire, pour tout $\varepsilon > 0$, $\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \varepsilon) = 0$.

Preuve (si $\text{Var}(X_i) = \sigma^2 < \infty$ existe pour tout i). On a $\mathbb{E}[\bar{X}_n] = \mu$ et $\text{Var}(\bar{X}_n) = \frac{1}{n^2} \text{Var}(\sum X_i) = \frac{1}{n^2} \sum \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$. Par l'inégalité de Bienaymé-Tchebychev appliquée à $\bar{X}_n$:

$$P(|\bar{X}_n - \mathbb{E}[\bar{X}_n]| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2}$$

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2/n}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}$$

Quand $n \rightarrow \infty$, $\frac{\sigma^2}{n\varepsilon^2} \rightarrow 0$ (car σ^2 et ε^2 sont fixes et finis). Donc $\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \varepsilon) = 0$. D'où $\bar{X}_n \xrightarrow{P} \mu$. $\square$

Exemple 5.22 (Jeu de Casino et TCL/LFGN). Considérons un jeu de casino où un joueur gagne 1€ avec probabilité p et perd 1€ avec probabilité $1 - p$. Soit X_i le gain à la i -ème partie. $\mathbb{E}[X_i] = 1 \cdot p + (-1) \cdot (1 - p) = 2p - 1$. $\mathbb{E}[X_i^2] = 1^2 \cdot p + (-1)^2 \cdot (1 - p) = 1$. $\text{Var}(X_i) = \mathbb{E}[X_i^2] - (\mathbb{E}[X_i])^2 = 1 - (2p - 1)^2 = 4p(1 - p)$. Notons $\mu = 2p - 1$ et $\sigma^2 = 4p(1 - p)$. Si $p < 1/2$, alors $\mu < 0$. La LFGN indique que $\bar{X}_n = S_n/n \xrightarrow{P} \mu < 0$, donc en moyenne, le joueur perd. Pour n grand, quelle est la probabilité que le gain total S_n soit non négatif, $P(S_n \geq 0)$? Par le TCL, $Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} \approx Z \sim \mathcal{N}(0, 1)$.

$$\begin{aligned} P(S_n \geq 0) &= P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \geq \frac{0 - n\mu}{\sigma\sqrt{n}}\right) \\ &\approx P\left(Z \geq -\frac{\sqrt{n}\mu}{\sigma}\right) = 1 - \Phi\left(-\frac{\sqrt{n}\mu}{\sigma}\right) \end{aligned}$$

Puisque $\mu < 0$, le terme $-\frac{\sqrt{n}\mu}{\sigma}$ est positif et tend vers $+\infty$ quand $n \rightarrow \infty$. Donc $\Phi\left(-\frac{\sqrt{n}\mu}{\sigma}\right) \rightarrow 1$, et $P(S_n \geq 0) \rightarrow 0$. *Application numérique (comme dans les notes originales) : Si $p = 0.45$ et $n = 100$. $\mu = 2(0.45) - 1 = -0.1$. $\sigma^2 = 4(0.45)(0.55) = 0.99 \implies \sigma \approx 0.995$. La borne devient $-\frac{\sqrt{100}(-0.1)}{0.995} = \frac{10 \times 0.1}{0.995} \approx \frac{1}{0.995} \approx 1.005$. $P(S_{100} \geq 0) \approx 1 - \Phi(1.005) \approx 1 - 0.8425 \approx 0.1575 \approx 0.16$.*

5.5.3 Loi Forte des Grands Nombres (LFFGN)

Soient $X_1, X_2, \dots$ une suite de variables aléatoires i.i.d. avec une espérance commune $\mathbb{E}[X_i] = \mu < \infty$. Alors la moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ converge presque sûrement vers μ :

$$\bar{X}_n \xrightarrow{p.s.} \mu$$

C'est-à-dire $P(\lim_{n \rightarrow \infty} \bar{X}_n = \mu) = 1$. La convergence presque sûre est une condition plus forte que la convergence en probabilité.

Exemple 5.23 (Interprétation fréquentiste de la probabilité). Soit A un événement associé à une expérience aléatoire, et $P(A)$ sa probabilité. On répète l'expérience n fois de manière indépendante. Soit $X_i = \mathbb{1}_A$ se réalise à l'essai i (variable indicatrice). Alors $X_i \sim \text{Bernoulli}(P(A))$, et $\mathbb{E}[X_i] = P(A)$. La moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ est la fréquence observée de l'événement A sur n essais. Par la LFFGN, $\bar{X}_n \xrightarrow{p.s.} \mathbb{E}[X_i] = P(A)$. La fréquence empirique de réalisation d'un événement converge (presque sûrement) vers sa probabilité théorique lorsque le nombre d'essais tend vers l'infini. C'est la justification mathématique rigoureuse de l'approche fréquentiste des probabilités.

Index des Notions

- Absence de mémoire (propriété d'), 28
- Algèbre d'ensembles, 11
- Analyse combinatoire, 4–10
- Arrangement
 - avec répétition, 6
 - sans répétition (A_n^k), 5
- Aversion au risque
 - aimant le risque (risk-loving), 48
 - averse au risque (risk-averse), 48
- Axiomatique des probabilités, 10–13
- Bayes (formule de), 15
- Bernstein (exemple de) pour indépendance, 17
- Binôme de Newton, 8–9
- Borel-Cantelli (lemme de), 19–20, 50
 - application (Pile ou Face), 20
- $\mathcal{B}(\mathbb{R})$, 21
- Card(A), 3
- Centrage-réduction (variable normale), 29
- $\binom{n}{k}$, 5
- Coefficient multinomial, 40
- Combinaison
 - avec répétition, 6
 - sans répétition ($\binom{n}{k}$), 5–6
- Combinatoire
 - et récursions, 9–10
- Continuité de la mesure de probabilité, 18
- Continuous Mapping Theorem (CMT)
 - pour convergence en distribution, 49
 - pour convergence en probabilité, 49
 - pour convergence presque sûre, 50
- Convergence (de suites de v.a.), 48–51
 - comparaison des modes, 50
 - en distribution ($\xrightarrow{d}$), 48–49
 - en moyenne L^r ($\xrightarrow{L^r}$), 50
 - en moyenne (L^1), 50
 - en moyenne quadratique (L^2), 50
 - en probabilité ($\xrightarrow{P}$), 49
 - presque sûre ($\xrightarrow{p.s.}$), 49–50
- Convolution (produit de), 43
- Cov(X, Y), 36–37
 - nulle n'implique pas indépendance, 37
 - interprétation, 36
- CDF (Fonction de répartition), 21–23
- Densité de probabilité, 25
 - conditionnelle, 41
 - définition, 25
 - interprétation, 26
 - jointe ($f_{X,Y}$), 34
 - marginale, 34
- Distribution conditionnelle, 41–42
 - cas continu, 41
 - cas discret, 41
- $\mathcal{P}(\Omega)$, 3
- $(\Omega, \mathcal{F}, \mathbb{P})$, 4, 10–13
- Espérance, 26
 - conditionnelle
 - cas continu, 41
 - cas discret, 41
 - comme variable aléatoire, 42–44
 - définition formelle, 42
 - propriétés, 43
 - itérée (Tower property), 43
 - linéarité, 31
 - monotonie, 31
 - produit de v.a. indépendantes, 35
 - propriétés, 24, 31
 - variable continue, 25–26
 - variable discrète, 24–25
 - vecteur aléatoire, 39
- Expérience aléatoire, 3
- Factorielle (n), 5
- Fonction caractéristique ($\varphi_X(t)$), 51–52
 - lien avec les moments, 52
 - propriétés, 51
 - somme de v.a. indépendantes, 52
 - théorème d'unicité, 52
 - théorème de Lévy, 52

- Fonction concave, 46
- Fonction convexe, 46
- Fonction d'utilité, 47
- Fonction de masse
 - conditionnelle, 41
 - conjointe (p_{ij}) , 32
 - conjointe (loi multinomiale), 40
- Fonction de répartition
 - définition, 21–23
 - jointe $(F_{X,Y})$, 32
 - jointe (vecteur aléatoire), 38
- Loi exponentielle, 28
- Loi normale, 29
- Loi uniforme, 27
- marginale, 34
- propriétés, 22
- utilisation, 22
- Formule de Huygens
 - pour la covariance, 36
- Formule de Poincaré, 13
- Inclusion-exclusion (principe d'), 13
 - généralisé, 13
- Indépendance
 - caractérisations, 35
 - d'événements, 14–18
 - deux événements, 16
 - mutuelle, 17
 - de variables aléatoires, 35–37
 - mutuelle (vecteur aléatoire), 38
- Inférence bayésienne, 42
- Inégalité de Bienaymé-Tchebychev, 46
- Inégalité de Boole, 13
- Inégalité de Jensen, 46–48
 - application (choix d'investissement), 47
- Inégalité de Markov, 45–46
 - généralisation, 45
- Inégalités de probabilité, 45–48, 54
- Kolmogorov (axiomatique de), 10–13
- Lemme de Slutsky, 49, 51
- Lindeberg-Lévy (TCL de), 52
- Loi Beta ($\mathcal{B}\text{eta}$), 42
- Loi Binomiale ($\mathcal{B}$)
 - marginale de multinomiale, 40
- Loi d'Erlang, 28–29
 - somme d'exponentielles, 29
- Loi de Bernoulli
 - couple, 32
- Loi de l'espérance totale, 43
- Loi de probabilité (d'une v.a.), 21
- Loi des Grands Nombres
 - Faible (LFGN), 53
 - Forte (LFFGN), 54
- Loi Exponentielle ($\mathcal{E}$), 28
- Loi Gamma (cas particulier Erlang), 28–29
- Loi Gaussienne, 29
- Loi marginale, 34
 - cas continu, 34
 - cas discret, 34
- Loi Multinomiale ($\mathcal{M}$), 39–41
 - propriétés, 40
- Loi normale
 - centrée réduite $(\mathcal{N}(0, 1))$, 29
 - densité $(\phi(z))$, 29
 - fonction caractéristique, 52
 - fonction de répartition $(\Phi(z))$, 29
 - somme de v.a. indépendantes, 30
 - transformation affine, 30
- Loi Normale ($\mathcal{N}$), 29
- Loi uniforme
 - sur un domaine, 34
- Loi Uniforme ($\mathcal{U}$), 27
- LOTUS (Loi de l'espérance inconsciente), 26
 - cas discret, 24
- Masse de probabilité, 31
- Σ (Matrice de covariance), 39
- Mesurable (fonction), 21
- Mesure de probabilité, 3, 11
- Moment (d'une variable aléatoire), 31
 - calcul par f.c., 52
- Monty Hall (problème de), 16
- Moyenne empirique, 52
- Ω (Univers), 3

- Paradoxe des anniversaires, 10
- Partition d'un ensemble, 14
- Pascal (identité de), 7
- Pascal (triangle de), 7–8
- Permutation, 5
- Presque sûrement (p.s.), 31
- Principe du dénombrement, 4
- Principe multiplicatif, 4
- Probabilité
 - Interprétation fréquentiste, 4
 - Interprétation fréquentiste (via LFFGN), 54
 - Mesure de, 3, 11
 - continuité, 18
 - propriétés, 12
- Probabilité conditionnelle, 14–18
 - définition, 14
- Probabilités composées (formule des), 14
- Probabilités totales (formule des), 14
- Récurrence (relation de), 9
- σ -additivité, 11
- σ -algèbre ($\mathcal{F}$), 4–13
 - $\sigma(Y)$ -mesurable, 43
- Singe savant (paradoxe du), 20
- Sous-additivité, 13
- Standardisation (variable normale), 29
- Suite d'événements, 18–20
 - croissante, 18
 - décroissante, 18
 - limite inférieure (liminf), 19
 - limite supérieure (limsup), 19
- Tchebychev (inégalité de), 46
- Théorème Central Limite (TCL), 52–53
- Théorème de Bayes, 15
- Théorème de la convergence dominée, 51
- Théorème de Lévy (continuité des f.c.), 52
- Théorème de transfert (LOTUS), 26
 - cas discret, 24
- Théorème des probabilités totales, 14
- Théorèmes limites, 52–54
- Triangle de Pascal, 7–8
- σ -algèbre ($\mathcal{F}$), 4–13
 - propriétés, 11
- Ω (Univers), 3–13
- Urnes (modèles d'), 6–7
 - exemple de loi jointe, 33
 - preuves, 6
- Urnes de minuit (exemple des), 19
- Variable aléatoire
 - absolument continue, 25
 - approximation d'une continue par une discrète, 26
 - couple continu, 34
 - couple discret, 32–34
 - discrète, 23–25
 - définition, 23
 - espérance, 24
 - variance, 25
 - définition, 21
 - définition et loi, 21–23
 - générale (mixte), 30–31
 - mixte, 30
- Variables non corrélées, 37
- Variance, 26
 - propriétés, 25
 - somme de v.a. indépendantes, 36
 - variable continue, 25–26
 - variable discrète, 25
- Vecteur aléatoire, 38–44
 - couple (X, Y) , 32
 - définition, 38
- Vraisemblance, 42
- Écart-type (σ), 25
- Équiprobabilité, 3, 4
- Étoiles et barres (méthode des), 7
- Événement, 3, 11
 - certain, 3
 - complémentaire (A^c), 3
 - différence symétrique ($A\Delta B$), 11
 - impossible, 3
 - intersection ($\cap$), 3
 - réalisé, 3
 - union ($\cup$), 3