


UNIVERSITÉ DE MONS · FACULTÉ DES SCIENCES



Statistiques

Notes de cours

TIAGO PIETTE

BaB3 — Sciences mathématiques

2026–2027

TABLE DES MATIÈRES

1	Introduction	2
1.1	Statistiques et probabilité	2
1.1.1	Méthodes statistiques	2
1.2	Statistiques descriptives	3

1. INTRODUCTION

1.1 STATISTIQUES ET PROBABILITÉ

Les statistiques consistent à l'analyse de données issues de phénomènes aléatoires. Elles servent à comprendre la **variabilité des données** et à permettre des **prédictions** sur des phénomènes futurs.

Exemple 1.1.1. Voici quelques exemples de situations où les statistiques sont utilisées :

- La météo : les prévisions météorologiques sont basées sur l'analyse de données.
- Résultats d'une élection : les sondages sont utilisés pour prédire les résultats d'une élection.
- Cours de la bourse : les analystes financiers utilisent des données historiques pour prédire les tendances du marché.

Tous ces phénomènes sont liés au hasard et induisent :

- Des phénomènes complexes
- Erreurs de mesure
- Incapacité à connaître tous les éléments d'une population

On distingue **deux types de statistiques** :

Statistiques descriptives : Méthodes qui visent à représenter/synthétiser un échantillon de données.

Statistiques inférentielles : Méthodes qui visent à induire les caractéristiques d'une population à partir d'un échantillon de données. Cela induit donc des probabilités.

1.1.1 MÉTHODES STATISTIQUES

Les méthodes statistiques sont des outils qui permettent d'analyser et d'interpréter les données. En voici quelques-unes :

1. Collecte de données
2. Exploration de données (Statistiques descriptives)
3. Modèle Probabiliste ($\mathcal{P}(\sigma)$)
4. Inférence statistiques (trouver un bon σ)
5. Prédictions

Les probabilités est une théorie mathématique abstraite qui donne un sens mathématique au hasard et d'en étudier les objets (v.a, TCL, LGN). Les statistiques répondent à la question "au vu de mes données, quel est le modèle probabiliste le plus approprié".

1.2 STATISTIQUES DESCRIPTIVES

En dimension 1 :

Un échantillon de données se note comme $\{x_1, x_2, \dots, x_n\}$. où $x_i \in \mathbb{R}$.

Pour les étudiants on dispose de plusieurs indicateurs statistiques :

1. Indicateurs de position :

- Moyenne empirique : $\bar{x} = \sum_{i=1}^n \frac{x_i}{n}$
- Médiane : $m = \inf\{x_i \mid x_i \leq x_j \text{ pour } 50\% \text{ des } j\}$
- Extrêmes : $x_{(n)} = \max\{x_i \mid i = 1, \dots, n\}$ et $x_{(1)} = \min\{x_i \mid i = 1, \dots, n\}$

2. Indicateurs de dispersion :

- Variance empirique : $s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n}$
- Écart-type empirique : $s = \sqrt{s^2}$
- Ecart absolu : $d = \sum_{i=1}^n \frac{|x_i - \bar{x}|}{n}$

Remarque 1.2.1 (Paradoxe de Simpson). Tous ces outils sont absolument nécessaires pour ne pas mal interpréter les données. La paradoxes de Simpson est un exemple célèbre de mauvaise interprétation des données :

"Une tendance observée dans les sous-groupes de données peut s'inverser lorsque les groupes de données sont combinés".


Pour l'illustrer, voici un exemple de données sur un cours qui a deux ans d'existence avec deux prof un pour chaque examen, un oral et un écrit

	Oral	Écrit	Total
2025	40% 20/50	80% 40/50	60%
2026	35% 7/20	75% 60/80	67%

En conclusion, en regardant le total, on pourrait penser que les élèves se sont améliorés mais en réalité, les examens regardés individuellement d'une année à l'autre, on voit que le niveau a diminué. Voici un autre exemple illustrant ce paradoxe :

"La dette a augmenté de 14% cette année, alors que c'était 15% l'année dernière".

Les uns disent que la dette a diminué, les autres qu'elle n'a jamais autant augmenté.



"Les accidents de la route sont la première cause de mortalité en Belgique"

Mais cela dépend de comment on définit les causes de mortalité. En effet,

- $\left\{ \underset{300}{\text{accident}}, \underset{200}{\text{maladies}}, \underset{240}{\text{incendie}}, \underset{200}{\text{naturelle}}, \underset{120}{\text{suicide}} \right\}$
- $\left\{ \underset{300}{\text{accident}}, \underset{240}{\text{incendie}}, \underset{120}{\text{suicide}}, \underset{400}{\text{naturelle + maladie}} \right\}$

En dimension 2 :

Un échantillon de données se note comme $\{(x_i, y_i)\}_{i=1, \dots, n}$

1. Indicateur univariés : $\bar{x}, \bar{y}, s_x^2, s_y^2, \dots$
2. Covariance empirique : On pose

$$s_{x,y} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$$

On l'interprète de deux manières :

Interprétation 1 : Si $s_{x,y} > 0$, un x_i plus grand a tendance à être associé à un y_i plus grand.

Interprétation 2 : Si $s_{x,y} < 0$, un x_i plus grand a tendance à être associé à un y_i plus petit.

On définit ensuite le coefficient de corrélation :

$$\text{corr}_{x,y} = \frac{s_{x,y}}{s_x s_y}$$

3. Nuage de points : Pour un échantillon $\{(x_i, y_i)\}_{i=1, \dots, n}$, on cherche la droite $\mathcal{D} : y = ax + b$ qui résume la tendance du nuage. Le résidu d'une observation est l'écart vertical

$$\varepsilon_i = y_i - (ax_i + b),$$


et l'on choisit (a, b) minimisant la somme des carrés des résidus :

$$f(a, b) = \sum_{i=1}^n (y_i - (ax_i + b))^2 = \sum_{i=1}^n \varepsilon_i^2.$$


f étant convexe, le minimum s'obtient en annulant les dérivées partielles :

$$\begin{cases} \frac{\partial f}{\partial a} = 0 \\ \frac{\partial f}{\partial b} = 0 \end{cases} \implies a = \frac{s_{xy}}{s_x^2}, \quad b = \bar{y} - \bar{x} \frac{s_{xy}}{s_x^2}.$$

La pente a donc le signe de s_{xy} , et la droite passe par le point moyen $(\bar{x}, \bar{y})$ puisque $y - \bar{y} = a(x - \bar{x})$.



droite de régression



$$\varepsilon_i^2 = (y_i - (ax_i + b))^2$$