

Théorie des Langages Formels

Introduction aux fondements

Tiago Piette

November 17, 2025

Contents

1 Fondements

1.1 Définitions de base

Définition 1.1 (Alphabet)

Un **alphabet** est un ensemble *fini* non vide de symboles. On le note généralement par Σ ou A .

Définition 1.2 (Mot)

Un **mot** (ou **chaîne**) sur un alphabet Σ est une séquence *finie* de symboles de Σ . Le **mot vide**, noté ε (ou parfois λ), est la séquence ne contenant aucun symbole.

Remarque. La finitude est essentielle : un mot a toujours une longueur dans $\mathbb{N}$. Les séquences infinies (appelées ω -mots) appartiennent à une théorie distincte.

Définition 1.3 (Longueur d'un mot)

Soit w un mot sur Σ . La **longueur** de w , notée $|w|$, est le nombre de symboles qui le composent. Par convention, $|\varepsilon| = 0$.

Exemples :

- Si $\Sigma = \{a, b\}$ et $w = abba$, alors $|w| = 4$.
- Si $w = a$, alors $|w| = 1$.
- $|\varepsilon| = 0$.

Définition 1.4 (Clôture de Kleene)

Soit Σ un alphabet. La **clôture de Kleene** (ou **étoile de Kleene**) de Σ , notée Σ^* , est l'ensemble de tous les mots finis sur Σ , y compris le mot vide :

$$\Sigma^* = \{\varepsilon\} \cup \{w : w \text{ est un mot sur } \Sigma\}$$

On note également $\Sigma^+ = \Sigma^* \setminus \{\varepsilon\}$ l'ensemble des mots non vides.

Proposition 1.5 (Cardinalité de Σ^*)

Pour tout alphabet Σ non vide, l'ensemble Σ^* est *dénombrable infini*.

Proof. Soit Σ un alphabet avec $|\Sigma| = n \geq 1$.

Pour chaque $k \in \mathbb{N}$, notons Σ^k l'ensemble des mots de longueur exactement k :

- $\Sigma^0 = \{\varepsilon\}$, donc $|\Sigma^0| = 1$
- $\Sigma^1 = \Sigma$, donc $|\Sigma^1| = n$
- Σ^2 contient tous les mots de longueur 2, donc $|\Sigma^2| = n^2$

- En général, $|\Sigma^k| = n^k$

Puisque $\Sigma^* = \bigcup_{k=0}^{\infty} \Sigma^k$ (union dénombrable d'ensembles finis), Σ^* est dénombrable. De plus, $\Sigma^* \supseteq \Sigma^+ \supseteq \{a^k : k \in \mathbb{N}\}$ pour tout $a \in \Sigma$, donc Σ^* est infini. $\square$

1.2 Opérations sur les mots

Définition 1.6 (Concaténation)

Soient u et v deux mots sur Σ . La **concaténation** de u et v , notée $u \cdot v$ ou simplement uv , est le mot obtenu en écrivant les symboles de u suivis de ceux de v .

Exemples :

- Si $u = ab$ et $v = ba$, alors $uv = abba$.
- $\varepsilon \cdot w = w \cdot \varepsilon = w$ pour tout mot w (élément neutre).

Proposition 1.7 (Propriétés de la concaténation)

La concaténation de mots possède les propriétés suivantes :

1. **Associativité** : $(uv)w = u(vw)$ pour tous mots u, v, w
2. **Élément neutre** : $\varepsilon \cdot w = w \cdot \varepsilon = w$ pour tout mot w
3. **Non-commutativité** : En général, $uv \neq vu$
4. **Additivité des longueurs** : $|uv| = |u| + |v|$

Remarque. L' ensemble $(\Sigma^*, \cdot, \varepsilon)$ forme un **monoïde libre** sur Σ .

Définition 1.8 (Puissance d'un mot)

Soit w un mot et $n \in \mathbb{N}$. On définit la **puissance** w^n par récurrence :

- $w^0 = \varepsilon$
- $w^{n+1} = w^n \cdot w$

Exemples :

- $a^3 = aaa$
- $(ab)^2 = abab$
- $w^0 = \varepsilon$ pour tout w

1.3 Langages

Définition 1.9 (Langage)

Un **langage** sur un alphabet Σ est un sous-ensemble de Σ^* :

$$L \subseteq \Sigma^*$$

Un langage peut être fini ou infini.

Exemples avec $\Sigma = \{a, b\}$:

1. $L_1 = \emptyset$ (langage vide)
2. $L_2 = \{\varepsilon\}$ (langage contenant uniquement le mot vide)
3. $L_3 = \{a, b, ab, ba\}$ (langage fini)
4. $L_4 = \{a^n : n \in \mathbb{N}\} = \{\varepsilon, a, aa, aaa, \dots\}$ (langage infini)
5. $L_5 = \{a^n b^n : n \in \mathbb{N}\}$ (même nombre de a et de b)
6. $L_6 = \Sigma^*$ (langage universel)

Remarque. *Il ne faut pas confondre :*

- $\emptyset$: le langage vide (aucun mot)
- $\{\varepsilon\}$: le langage contenant uniquement le mot vide

1.4 Opérations sur les langages

Définition 1.10 (Opérations ensemblistes)

Soient $L_1, L_2 \subseteq \Sigma^*$ deux langages. On définit :

- **Union** : $L_1 \cup L_2 = \{w : w \in L_1 \text{ ou } w \in L_2\}$
- **Intersection** : $L_1 \cap L_2 = \{w : w \in L_1 \text{ et } w \in L_2\}$
- **Complémentaire** : $\overline{L_1} = \Sigma^* \setminus L_1$
- **Différence** : $L_1 \setminus L_2 = \{w : w \in L_1 \text{ et } w \notin L_2\}$

Définition 1.11 (Concaténation de langages)

Soient $L_1, L_2 \subseteq \Sigma^*$. La **concaténation** de L_1 et L_2 est :

$$L_1 \cdot L_2 = \{uv : u \in L_1 \text{ et } v \in L_2\}$$

Exemples :

- Si $L_1 = \{a, ab\}$ et $L_2 = \{b, ba\}$, alors

$$L_1 \cdot L_2 = \{ab, aba, abb, abba\}$$

- $\emptyset \cdot L = L \cdot \emptyset = \emptyset$ pour tout langage L
- $\{\varepsilon\} \cdot L = L \cdot \{\varepsilon\} = L$ pour tout langage L

Proposition 1.12 (Propriétés de la concaténation)

Pour tous langages L_1, L_2, L_3 :

1. **Associativité** : $(L_1 \cdot L_2) \cdot L_3 = L_1 \cdot (L_2 \cdot L_3)$
2. **Élément neutre** : $\{\varepsilon\} \cdot L = L \cdot \{\varepsilon\} = L$
3. **Élément absorbant** : $\emptyset \cdot L = L \cdot \emptyset = \emptyset$
4. **Distributivité (partielle)** :
 - $L_1 \cdot (L_2 \cup L_3) = (L_1 \cdot L_2) \cup (L_1 \cdot L_3)$
 - $(L_1 \cup L_2) \cdot L_3 = (L_1 \cdot L_3) \cup (L_2 \cdot L_3)$
5. **Non-commutativité** : En général, $L_1 \cdot L_2 \neq L_2 \cdot L_1$

Définition 1.13 (Puissance d'un langage)

Soit $L \subseteq \Sigma^*$ et $n \in \mathbb{N}$. On définit :

- $L^0 = \{\varepsilon\}$
- $L^{n+1} = L^n \cdot L$

Définition 1.14 (Étoile de Kleene d'un langage)

Soit $L \subseteq \Sigma^*$. L'**étoile de Kleene** de L , notée L^* , est :

$$L^* = \bigcup_{n=0}^{\infty} L^n = L^0 \cup L^1 \cup L^2 \cup \dots$$

On définit également $L^+ = \bigcup_{n=1}^{\infty} L^n = L^* \setminus \{\varepsilon\}$ (si $\varepsilon \notin L$).

Exemples :

- Si $L = \{a\}$, alors $L^* = \{\varepsilon, a, aa, aaa, \dots\} = \{a^n : n \in \mathbb{N}\}$
- Si $L = \{a, b\}$, alors $L^* = \Sigma^*$ (tous les mots sur $\{a, b\}$)
- Si $L = \{ab\}$, alors $L^* = \{\varepsilon, ab, abab, ababab, \dots\}$

Proposition 1.15 (Propriétés de l'étoile de Kleene)

Pour tout langage L :

1. $\varepsilon \in L^*$
2. $L \subseteq L^*$
3. $(L^*)^* = L^*$
4. $\emptyset^* = \{\varepsilon\}$
5. Si $\varepsilon \in L$, alors $L^* = L^+$

2 Résultats fondamentaux

Théorème 2.1 (Cardinalité de l'ensemble des langages)

L'ensemble de tous les langages sur un alphabet Σ (c'est-à-dire $\mathcal{P}(\Sigma^*)$) est *non dénombrable*.

Proof. Puisque Σ^* est dénombrable infini (Proposition 1.1), et que $\mathcal{P}(\Sigma^*)$ a la cardinalité du continu (par le théorème de Cantor), il existe strictement plus de langages que de mots.

En particulier, cela implique qu'il existe des langages qui ne peuvent pas être décrits par un algorithme fini. $\square$

Lemme 2.2 (Monotonie de la concaténation)

Si $L_1 \subseteq L_2$ et $L_3 \subseteq L_4$, alors :

$$L_1 \cdot L_3 \subseteq L_2 \cdot L_4$$

Proof. Soit $w \in L_1 \cdot L_3$. Alors $w = uv$ avec $u \in L_1$ et $v \in L_3$.

Puisque $L_1 \subseteq L_2$ et $L_3 \subseteq L_4$, on a $u \in L_2$ et $v \in L_4$.

Donc $w = uv \in L_2 \cdot L_4$. $\square$

Proposition 2.3 (Idempotence de l'étoile)

Pour tout langage L :

$$(L^*)^* = L^*$$

Proof. **Inclusion** $L^* \subseteq (L^*)^*$:

Par définition, $L^* \subseteq (L^*)^*$ car $(L^*)^* = \bigcup_{n=0}^{\infty} (L^*)^n$ et $(L^*)^1 = L^*$.

Inclusion $(L^*)^* \subseteq L^*$:

Montrons que $(L^*)^n \subseteq L^*$ pour tout $n \in \mathbb{N}$ par récurrence.

Cas de base : $(L^*)^0 = \{\varepsilon\} \subseteq L^*$ car $\varepsilon \in L^*$.

Hérédité : Supposons $(L^*)^k \subseteq L^*$. Alors :

$$(L^*)^{k+1} = (L^*)^k \cdot L^* \subseteq L^* \cdot L^*$$

Or, pour tous $u, v \in L^*$, il existe $m, n \in \mathbb{N}$ tels que $u \in L^m$ et $v \in L^n$.

Donc $uv \in L^m \cdot L^n = L^{m+n} \subseteq L^*$.

Ainsi $(L^*)^{k+1} \subseteq L^*$.

Par conséquent, $(L^*)^* = \bigcup_{n=0}^{\infty} (L^*)^n \subseteq L^*$. □

3 Conclusion

Cette introduction aux langages formels pose les bases pour l'étude des :

- **Automates finis** : machines reconnaissant les langages réguliers
- **Grammaires formelles** : systèmes générateurs de langages
- **Hiérarchie de Chomsky** : classification des langages selon leur complexité
- **Décidabilité** : questions algorithmiques sur les langages

La théorie des langages est au cœur de l'informatique théorique, de la compilation et de la logique formelle.